



Ecole Supérieure de la Statistique et de l'Analyse  
De l'Information

## **Rapport Projet De Fin d'Année**

Niveau : 2<sup>eme</sup> Année

---

# **Analyse Temporelle des Effets de la Politique Économique sur la croissance : Processus VAR et Application Empirique**

---

Elaboré par :  
**Nour Sfar**

Encadré par :  
**Mme. Selma Jelassi**

**A.U: 2023/2024**

# REMERCIEMENT

---

Avant de commencer ce rapport, nous aimerions exprimer notre gratitude envers notre professeure, Madame Selma Jelassi, pour son soutien constant tout au long du projet. Nous tenons à la remercier pour sa générosité en termes de formation et d'encadrement, ainsi que pour ses conseils précieux lors des différentes étapes de suivi, en lien avec les missions abordées dans ce rapport.

# SOMMAIRE

---

<b>Généralité .....</b>	<b>1</b>
<b>A. Aspect théorique : .....</b>	<b>2</b>
<b>I. Théorie économique.....</b>	<b>2</b>
1) Croissance économique : .....	2
2) Politique économique : .....	2
3) Masse monétaire: .....	2
4) Inflation .....	2
<b>II. Méthodes temporelles : .....</b>	<b>3</b>
1) Modélisation VAR : .....	3
2) Approche de causalité selon Granger-Engle (1969) : .....	5
3) Causalité de Sims (1980) : .....	7
4) Approche de cointégration : .....	7
5) Effet d'impulsion et Décomposition de la variance .....	8
<b>B. Aspect pratique : .....</b>	<b>9</b>
<b>I. Présentation des variables et analyse de Box-Jenkins .....</b>	<b>9</b>
1) Base de données : .....	9
2) Représentation graphique des séries : .....	9
3) Etude des processus : test ADF .....	13
a) L'inflation : .....	13
b) Masse monétaire : .....	13
c) PIB : .....	17
d) Dépenses : .....	18
<b>II. Modélisation VAR : .....</b>	<b>22</b>
1) Détermination du lag optimal et tests de diagnostics : .....	22
a) Estimation du VAR : .....	22
b) Vérification de la stationnarité du processus : .....	23
c) Approche de causalité : .....	25
2) Diagnostique du VAR estimé : .....	26
a) Résultat sous forme d'équation : .....	26
b) Tests post-estimations : .....	26

3) Cointégration :.....	28
4) Fonctions de réponses impulsionnelles et Structure Dynamique du processus VAR .....	29
a) Analyse graphique des fonctions de réponse impulsionnelle :.....	29
b) Décomposition de la variance :.....	32
5) VECM :.....	33
<b>Conclusion</b> .....	<b>35</b>
<b>Bibliographie</b> .....	<b>36</b>
<b>Annexe</b> .....	<b>37</b>

# Généralité

L'analyse de séries temporelles est un domaine puissant au sein de l'analyse statistique, se concentrant sur les données collectées au fil du temps, telles que la masse monétaire, afin de découvrir les tendances, les motifs saisonniers et d'autres insights cachés. Un objectif principal est la prévision des valeurs futures. Le but principal de l'analyse de séries temporelles est de modéliser la structure sous-jacente d'une série, facilitant la génération de simulations de données réalistes et de valeurs de fonction de prévision. Cela implique de capturer l'autocorrélation et le comportement global des données de séries temporelles.

Dans notre cas, nous utiliserons l'analyse de séries temporelles dans un contexte économétrique pour examiner comment les facteurs politico-économiques influencent la croissance (PIB) au Royaume-Uni. L'objectif de cette analyse temporelle est de mettre en place un modèle économique en utilisant les processus VAR (Vecteur Autorégressif) et la cointégration des variables économiques, afin d'identifier les relations temporelles entre les politiques économiques mises en place et l'évolution de la croissance. Ces résultats permettront d'élaborer des recommandations politiques plus précises pour favoriser une croissance durable dans le pays.

## **A. Aspect Théorique :**

### **I. Théorie Économique :**

#### **1) Croissance économique :**

La croissance économique désigne l'augmentation de la production de biens et de services sur une période donnée. Elle est mesurée par le produit intérieur brut (PIB), qui représente la valeur totale des biens et services produits dans un pays pendant une période spécifique.

#### **2) Politique économique :**

La politique économique est l'ensemble des mesures mises en œuvre par un gouvernement pour influencer l'économie d'un pays. Elle vise souvent à promouvoir la croissance économique tout en maintenant la stabilité. Dans ce contexte, la gestion de la masse monétaire est cruciale. La masse monétaire désigne la quantité totale de monnaie en circulation dans une économie à un moment donné. Lorsque les autorités monétaires mettent en œuvre des politiques qui augmentent la masse monétaire, cela peut avoir un impact sur l'inflation. En effet, une augmentation rapide de la masse monétaire peut entraîner une augmentation de la demande globale, ce qui peut à son tour entraîner une hausse des prix des biens et services, c'est ce qu'on appelle l'inflation. Ainsi, la politique économique doit souvent jongler avec la gestion de la masse monétaire afin de maintenir l'inflation à un niveau stable et contrôlé, crucial pour la stabilité économique d'un pays.

#### **3) Masse Monétaire :**

La masse monétaire fait référence à la quantité totale de monnaie en circulation dans une économie à un moment donné. Elle comprend la monnaie fiduciaire, telle que les billets de banque et les pièces de monnaie, ainsi que la monnaie scripturale, qui représente les dépôts bancaires. La masse monétaire est généralement mesurée en utilisant différentes agrégations, telles que M1, M2 ou M3, qui regroupent différentes formes de monnaie en fonction de leur liquidité.

#### **4) Inflation :**

L'inflation fait référence à l'augmentation générale et durable des prix des biens et services dans une économie au fil du temps. Elle peut être mesurée par l'indice des prix à la consommation (IPC), qui reflète les variations moyennes des prix des biens et services achetés par les ménages.

Ces concepts de masse monétaire et d'inflation sont essentiels pour comprendre l'impact de la politique monétaire sur la croissance économique.

## II. Méthode temporelle :

### 1) Modélisation VAR :

#### a- Présentation d'un modèle VAR :

Les modèles de VAR (Vector Autoregression) sont un type de modèle statistique utilisé pour analyser les relations causales entre plusieurs séries temporelles. Ils permettent de déterminer comment une variation dans une série temporelle (appelée variable dépendante) est causée par les variations dans d'autres séries temporelles (appelées variables explicatives ou indépendantes).

Un modèle VAR décrit l'évolution d'un ensemble de  $k$  variables, appelées variables endogènes, dans le temps. Chaque période de temps est numérotée,  $t = 1, \dots, T$ . Les variables sont rassemblées dans un vecteur,  $y_t$ , qui est de longueur  $k$ . (De manière équivalente, ce vecteur pourrait être décrit comme une matrice ( $k \times 1$ )). Le vecteur est modélisé comme une fonction linéaire de sa valeur précédente. Les composantes du vecteur sont appelées  $y_{i,t}$ , c'est-à-dire l'observation au temps  $t$  de la  $i$ -ème variable.

Par exemple, si la première variable est l'inflation, alors  $y_{1,2000}$  correspond à la valeur de l'inflation à l'année 2000.

Les modèles VAR sont définis par leur ordre, qui est le nombre de périodes précédentes incluses dans le modèle. Par exemple, un VAR d'ordre 5 prend en compte les taux d'inflation des cinq dernières années pour prédire le taux d'inflation actuel. Un retard est la valeur d'une variable à une période antérieure. Ainsi, en général, un VAR d'ordre  $p$  inclut les retards des  $p$  dernières périodes. Ce modèle est noté "VAR( $p$ )" et parfois appelé "VAR avec  $p$  retards".

Un modèle VAR de dimension  $k$  et d'ordre  $p$  est écrit comme suit :

$$Y_t = A_0 + A_1 Y_{t-1} + A_2 Y_{t-2} + \dots + A_p Y_{t-p} + e_t$$

$$\text{Avec : } Y_t = \begin{bmatrix} Y_t^1 \\ Y_t^2 \\ \vdots \\ Y_t^k \end{bmatrix} \quad A_i = \begin{bmatrix} a_{1i}^1 & \dots & a_{1i}^k \\ \vdots & \ddots & \vdots \\ a_{ki}^1 & \dots & a_{ki}^k \end{bmatrix} \quad A_0 = \begin{bmatrix} a_1^0 \\ a_2^0 \\ \vdots \\ a_k^0 \end{bmatrix} \quad \text{et } e_t = \begin{bmatrix} e_t^1 \\ e_t^2 \\ \vdots \\ e_t^k \end{bmatrix}$$

$y_{t-i}^k$  Représente la valeur de la variable  $y^k$  à  $i$ -périodes de temps, il est appelé «  $i$ -ème lag » de  $y_t$ . La variable  $A_0$  est un vecteur de constantes de taille  $k$  servant d'ordonnée à l'origine du modèle.  $A_i$  est une matrice invariante dans le temps de taille  $k \times k$  et est un vecteur de taille  $k$  représentant les termes d'erreur.

Le choix du nombre maximal de retards  $p$  dans le modèle VAR est important car la validité de l'inférence dépend de la précision de l'ordre de retard sélectionné.

Les modèles de VAR ont plusieurs avantages, tels que :

- Ils permettent d'analyser simultanément plusieurs variables, ce qui peut être utile lorsque les relations causales sont complexes.

Ils permettent d'évaluer les relations causales à court terme et à long terme entre les variables.

Ils peuvent être utilisés pour la prévision des séries temporelles.

Il y a cependant des limites à ces modèles, notamment :

- Ils supposent une relation linéaire entre les variables, ce qui peut ne pas être le cas dans la réalité.
- Ils ne tiennent pas compte des relations causales à sens unique.
- Ils nécessitent des données suffisamment longues pour générer des résultats fiables.

En somme, les modèles de VAR sont une méthode utile pour comprendre les relations causales entre les séries temporelles, mais ils doivent être utilisés avec prudence et en tenant compte de leurs limites.

#### b- Méthode d'estimation du modèle VAR :

Si les séries à modéliser sont stationnaires, nous les prévoyons en ajustant directement un VAR aux données (appelé "VAR en niveaux").

Si les séries sont non stationnaires, nous prenons des différences des données afin de les rendre stationnaires, puis ajustons un modèle VAR (appelé "VAR en différences").

Dans les deux cas, les modèles sont estimés équation par équation en utilisant le principe des moindres carrés. Pour chaque équation, les paramètres sont estimés en minimisant la somme des carrés des valeurs des résidus  $e_t^i$ .

#### c- Méthodes de validation d'un modèle VAR :

Après avoir estimé le modèle VAR, plusieurs tests peuvent être effectués pour diagnostiquer et valider l'adéquation du modèle.

- Test de Portmanteau pour l'autocorrélation :

Le test de Portmanteau est une technique statistique utilisée pour évaluer la présence d'autocorrélation dans les résidus du modèle. Il s'agit d'un test d'adéquation qui permet de vérifier si les résidus sont aléatoires et non corrélés. Pour cela, il est nécessaire de calculer la statistique de test de Portmanteau en utilisant les résidus du modèle, puis de comparer cette statistique avec les valeurs critiques de la distribution de référence. La statistique de Portmanteau sous  $H_0$  est :

$$PS(\tau) = \sum_{i=1}^{\tau} tr(ACF(i)'ACF(0)^{-1'} ACF(i)ACF(0)^{-1}) \xrightarrow{D} \chi^2(m^2(\tau - q)), \text{ pour } \tau > q$$

- Tests d'hétéroscédasticité :

En modélisation VAR, la détection de l'hétéroscédasticité est essentielle pour assurer l'exactitude du modèle. Deux tests couramment utilisés à cette fin sont le test ARCH et le test de White. Le test ARCH consiste à estimer les résidus au carré du modèle VAR et à les régresser sur leurs valeurs retardées pour détecter toute autocorrélation significative dans les données. D'autre part, le test de White consiste à régresser les résidus au carré sur leurs valeurs retardées et sur d'autres variables explicatives qui pourraient être pertinentes pour expliquer l'hétéroscédasticité. Si l'un de ces tests rejette l'hypothèse nulle d'homoscédasticité, cela suggère la présence d'hétéroscédasticité dans les données. Cependant, le test ARCH-LM est une extension du test ARCH qui régresse à la fois les résidus au carré et leur produit sur leurs valeurs retardées. Cela rend le test ARCH-LM une méthode plus puissante pour détecter des formes complexes d'hétéroscédasticité dans les données, en faisant un outil essentiel pour tester avec précision les modèles VAR.



## 2) Approche de causalité selon Granger-Engle (1969) :

Soient  $X_t$  et  $Y_t$  deux séries temporelles, et notons le passé de  $X_t$  et  $Y_t$ ,

$$X_t = \{X_t, X_{t-1}, \dots\} \text{ et } Y_t = \{Y_t, Y_{t-1}, \dots\}.$$

Granger a introduit en 1969 différentes notions de causalité :

(i) Y cause X à la date t si et seulement si :

$$E(X_t | X_{t-1}, Y_{t-1}) \neq E(X_t | X_{t-1})$$

(ii) Y cause X instantanément à la date t si et seulement si

$$E(X_t | X_{t-1}, Y_t) \neq E(X_t | X_{t-1}, Y_{t-1})$$

Il y a équivalence entre :

X ne cause pas Y instantanément à la date t **Et** Y ne cause pas X instantanément à la date t

### Test de Granger :

Supposons que  $P(X_t | \bar{X}_{t-1}, \bar{Y}_{t-1})$  est linéaire ou limitons-nous à la causalité linéaire. Si le processus a une représentation autorégressive,

$$X_t = \alpha_0 + \sum_{i=1}^{\infty} \alpha_i X_{t-i} + \sum_{j=1}^{\infty} \beta_j Y_{t-i} + \epsilon_t$$

Nous voulons tester que :

Y ne cause pas X

En testant l'hypothèse :

$$H_0 : \beta_i = 0, i = 1, 2, \dots$$

En pratique, on doit tronquer le modèle,

$$X_t = \alpha_0 + \sum_{i=1}^{n_1} \alpha_i X_{t-i} + \sum_{j=1}^{n_2} \beta_j Y_{t-i} + \epsilon_t$$

Et tester l'hypothèse

$$\bar{H}_0 : \beta_i = 0, i = 1, 2, \dots, n_2$$

Au moyen d'un test de Fisher

Si  $X_t$  et  $Y_t$  suivent des tendances linéaires, il est recommandable d'ajouter une variable de tendance (et, dans certains cas, des variables binaires de saisonnières) :

$$X_t = \alpha_0 + \gamma_t + \sum_{i=1}^{n_1} \alpha_i X_{t-i} + \sum_{j=1}^{n_2} \beta_j Y_{t-i} + \epsilon_t$$

La causalité de Granger est un concept statistique utilisé pour tester si une variable de série temporelle est utile pour prédire une autre variable de série temporelle. L'idée de base de la causalité de Granger est que si X est utile pour prédire Y, alors les valeurs passées de X doivent contenir des informations sur les valeurs futures de Y qui ne sont pas déjà prises en compte par les valeurs passées de Y.

Nous pouvons exprimer cette idée mathématiquement à l'aide de modèles de régression. Supposons que nous ayons deux variables de séries temporelles, X et Y, et que nous voulions tester si X provoque Y par effet de Granger :

Modèle 1 :

$$Y_t = a + b_1 Y_{t-1} + b_2 Y_{t-2} + \dots + b_p Y_{t-p} + e_t$$

Modèle 2 :

$$Y_t = a + b_1 Y_{t-1} + b_2 Y_{t-2} + \dots + b_p Y_{t-p} + X_t + c_1 X_{t-1} + c_2 X_{t-2} + \dots + c_q X_{t-q} + e_t$$

Dans le modèle 1, nous n'utilisons que les valeurs retardées de Y comme prédicteurs de  $Y_t$ . Dans le modèle 2, nous incluons à la fois les valeurs décalées de Y et les valeurs décalées de X comme prédicteurs de  $Y_t$ . Si X provoque Y par effet Granger, nous nous attendons à ce que l'ajout de X au modèle 2 améliore son pouvoir prédictif par rapport au modèle 1.

Nous pouvons tester la causalité de Granger à l'aide de la statistique du test F :

$$F = \frac{RSS_1 - RSS_2}{\frac{RSS_2}{n - p - q - 1}}$$

Où  $RSS_1$  est la somme des carrés résiduels pour le modèle 1,  $RSS_2$  est la somme des carrés résiduels pour le modèle 2, n est la taille de l'échantillon, p est le nombre de retards de Y dans les modèles, et q est le nombre de retards de X dans le modèle 2.

Si F est supérieur à la valeur critique pour un niveau de signification donné, nous rejetons l'hypothèse nulle selon laquelle X ne cause pas Y par effet de Granger et nous concluons que X cause Y par effet de Granger.

En résumé, la causalité de Granger est un concept statistique qui peut être testé à l'aide de modèles de régression et de tests F. Elle nous permet de déterminer si une période de temps est nécessaire à la réalisation d'un projet. Il nous permet de déterminer si une variable de série temporelle est utile pour prédire une autre variable de série temporelle, sur la base de l'idée que les valeurs passées du prédicteur devraient contenir des informations sur les valeurs futures de la réponse qui ne sont pas déjà capturées par les valeurs passées de la réponse

### 3) Causalité de Sims (1980) :

Sims (1980) présente une spécification de test légèrement différente, en considérant que si les valeurs futures de  $y_{1t}$  permettent d'expliquer les valeurs présentes de  $y_{2t}$ , alors  $y_{2t}$  est la cause de  $y_{1t}$ .

Ceci se traduit par la représentation suivante :

$$y_{1t} = a_1^0 + \sum_{i=1}^p a_{1i}^1 y_{1t-i} + \sum_{i=1}^p a_{1i}^2 y_{2t-i} + \sum_{i=1}^p b_i^2 y_{2t+i} + \varepsilon_{1t}$$

$$y_{2t} = a_2^0 + \sum_{i=1}^p a_{2i}^1 y_{1t-i} + \sum_{i=1}^p a_{2i}^2 y_{2t-i} + \sum_{i=1}^p b_i^1 y_{1t+i} + \varepsilon_{2t}$$

- $y_{1t}$  Ne cause pas  $y_{2t}$  si l'hypothèse suivante est acceptée  $H_0$  :

$$b_1^2 = b_2^2 = \dots = b_p^2 = 0.$$

- $y_{2t}$  Ne cause pas  $y_{1t}$  si l'hypothèse suivante est acceptée  $H_0$  :

$$b_1^1 = b_2^1 = \dots = b_p^1 = 0.$$

Il s'agit là encore d'un test de Fisher classique de nullité de coefficients.

### 4) Approche de cointégration :

La cointégration est un concept statistique qui fait référence à la relation d'équilibre à long terme entre deux ou plusieurs séries temporelles non stationnaires. En d'autres termes, si deux variables ou plus ont une relation de cointégration, elles auront tendance à évoluer ensemble à long terme, même si elles peuvent diverger à court terme.

Dans le contexte des modèles VAR, la cointégration implique qu'il existe une combinaison linéaire des variables qui est stationnaire. Cela signifie que même si chaque variable est non stationnaire en soi, il existe une combinaison de ces variables qui est stationnaire et qui peut être utilisée pour estimer les relations à long terme entre les variables.

Si la cointégration n'est pas trouvée dans un modèle VAR, cela signifie qu'il n'existe pas de relations d'équilibre à long terme entre les variables. Dans ce cas, il peut être approprié d'utiliser un modèle VAR différencié au lieu d'un VECM.

D'un point de vue mathématique, la cointégration peut être exprimée comme suit : Supposons que nous ayons deux séries temporelles non stationnaires  $Y_1$  et  $Y_2$ . S'il existe une combinaison linéaire de ces deux séries données par  $\beta_1 Y_1 + \beta_2 Y_2 = Z_t$  telle que  $Z_t$  est stationnaire, alors on dit que  $Y_1$  et  $Y_2$  sont cointégrées avec le vecteur de cointégration  $\beta = (\beta_1, \beta_2)$ . Le vecteur  $\beta$  représente la relation d'équilibre à long terme entre  $Y_1$  et  $Y_2$ .

La vérification de la cointégration entre deux ou plusieurs séries temporelles peut être effectuée à l'aide de tests statistiques tels que le test de Johansen ou le test d'Engle-Granger.

Le test de Johansen est basé sur la décomposition en valeurs propres d'une matrice de covariance des résidus d'un modèle VAR estimé. Ce test permet de tester l'hypothèse nulle selon laquelle il n'y a pas de relation de cointégration entre les séries. Si cette hypothèse est rejetée, cela indique qu'il existe une ou plusieurs relations de cointégration entre les séries.

## 5) Effet d'impulsion et Décomposition de la variance :

La décomposition de la variance de l'erreur de prévision a pour objectif de calculer pour chacune des innovations sa contribution à la variance de l'erreur. Par une technique mathématique, on peut écrire la variance de l'erreur de prévision à un horizon  $h$  en fonction de la variance de l'erreur attribuée à chacune des variables ; il suffit ensuite de rapporter chacune de ces variances à la variance totale pour obtenir son poids relatif en pourcentage.

Reprenons notre modèle VAR (1) à deux variables  $y_{1t}$  et  $y_{2t}$ , la variance de l'erreur de prévision pour  $y_{1t+h}$  peut s'écrire :

$$\sigma_{y_1}^2(h) = \sigma_{\varepsilon_1}^2 [m_{11}^2(0) + m_{11}^2(1) + \dots + m_{11}^2(h-1)] \\ + \sigma_{\varepsilon_2}^2 [m_{22}^2(0) + m_{22}^2(1) + \dots + m_{22}^2(h-1)]$$

Où les  $m_{ii}$  sont les termes de la matrice  $M$  :

$$M_i = \sum_{j=1}^{\min(p,i)} A_j M_{i-j} \quad i = 1, 2, \dots \text{ et } M_0 = I$$

À l'horizon  $h$ , la décomposition de la variance, en pourcentage, des propres innovations de  $y_{1t}$  sur  $y_{1t}$ , est donnée par :

$$\frac{\sigma_{\varepsilon_1}^2 [m_{11}^2(0) + m_{11}^2(1) + \dots + m_{11}^2(h-1)]}{\sigma_{y_1}^2(h)}$$

Et la décomposition de la variance, en pourcentage, des innovations de  $y_{1t}$  sur  $y_{2t}$ , est donnée par :

$$\frac{\sigma_{\varepsilon_2}^2 [m_{22}^2(0) + m_{22}^2(1) + \dots + m_{22}^2(h-1)]}{\sigma_{y_1}^2(h)}$$

L'interprétation des résultats est importante :

- si un choc sur  $\varepsilon_{1t}$  n'affecte pas la variance de l'erreur de  $y_{2t}$  quel que soit l'horizon de révision, alors  $y_{2t}$  peut être considéré comme exogène car  $y_{2t}$  évolue indépendamment de  $\varepsilon_{1t}$  ;
- a contrario, si un choc sur  $\varepsilon_{1t}$  affecte fortement – voire totalement – la variance de l'erreur de  $y_{2t}$ , alors  $y_{2t}$  est considéré comme endogène.

Dans la pratique, les résultats ne sont pas aussi marqués mais indiquent la contribution de chacune des variables à la variance de l'erreur.

## B. Aspect Pratique :

### I. Présentation des variables et stationnarité :

#### 1) Base de données :

Année	Dépenses (% du PIB)	Masse monétaire (% du PIB)	Croissance du PIB (% annuel)	Inflation, IPC (% annuel)
1/1/1972	29.5118582302289	38.1858524113204	4.32166758855182	7.07109839479797
1/1/1973	28.8380792426903	42.1698857419141	6.52384841665435	9.19603316657812
1/1/1974	33.2535749520883	42.4446888856129	-2.48440389712059	16.0440111889861
.	.	.	.	.
.	.	.	.	.
.	.	.	.	.
1/1/2022	45	163.940913824681	4.34656140089153	7.92204883147902

#### 2) Représentation graphique des séries :




Figure 1 - Représentation graphique des processus

En étudiant le graphique et les données historiques on peut avoir une idée préliminaire :

❖ Pour le taux d'inflation :

Les fluctuations de l'inflation au Royaume-Uni entre 1972 et 2022 ont été influencées par divers facteurs économiques, politiques et sociaux :

Années 1970 - Haute inflation : La période entre le début des années 1970 et le début des années 1980 a été marquée par une forte inflation au Royaume-Uni. Des chocs pétroliers, des politiques de dépenses publiques élevées et des négociations salariales importantes ont contribué à cette inflation élevée. L'inflation a culminé à des niveaux record de plus de 20 % au milieu des années 1970.

Années 1980 - Politique monétaire restrictive : Sous le gouvernement de Margaret Thatcher, une politique monétaire restrictive a été mise en œuvre pour réduire l'inflation. Cela a entraîné une période de récession économique au début des années 1980, mais a également permis de ramener l'inflation à des niveaux plus bas.

Années 1990 - Stabilité relative : Pendant les années 1990, l'inflation au Royaume-Uni est restée relativement stable, oscillant autour de 2 à 5 %. La Banque d'Angleterre a obtenu son indépendance en 1997, ce qui lui a permis de mettre en œuvre une politique monétaire plus efficace pour maintenir la stabilité des prix.

Années 2000 - Inflation modérée : La première décennie des années 2000 a connu une inflation modérée, bien que des fluctuations aient été observées en raison de facteurs tels que les prix de l'énergie et des matières premières.

Années 2010 - Impact de la crise financière : La crise financière mondiale de 2008 a entraîné une période d'inflation relativement faible en raison de la faiblesse de la demande et des politiques de relance monétaire mises en place par la Banque d'Angleterre pour stimuler l'économie.

Années 2020 - Volatilité due à la pandémie : La pandémie de COVID-19 a entraîné une volatilité significative de l'inflation au Royaume-Uni. Initialement, il y a eu des pressions déflationnistes en raison des restrictions économiques, mais par la suite, des pressions inflationnistes sont apparues en raison de la reprise économique et des pressions sur les prix, notamment dans les secteurs de l'énergie et des matériaux.

❖ Pour la masse monétaire :

La masse monétaire au Royaume-Uni a connu plusieurs fluctuations significatives de 1972 à 2022, influencées par divers facteurs économiques, politiques et monétaires :

Années 1970 : Pendant cette décennie, le Royaume-Uni a été confronté à une inflation élevée, en partie due à des chocs pétroliers et à une politique monétaire expansionniste. La masse monétaire a augmenté pour financer les dépenses publiques croissantes et soutenir la demande intérieure.

Années 1980 : Sous le gouvernement de Margaret Thatcher, le Royaume-Uni a adopté une politique monétaire plus restrictive pour lutter contre l'inflation. Cela a entraîné une certaine volatilité dans la masse monétaire, avec des périodes d'expansion suivies de mesures de resserrement.

Années 1990 : La politique monétaire est devenue plus axée sur le contrôle de l'inflation, avec l'adoption du ciblage de l'inflation comme objectif principal de la Banque d'Angleterre. La masse monétaire a été plus stable, mais les fluctuations sont toujours présentes en réponse aux conditions économiques et aux décisions politiques.

Années 2000 : La Grande-Bretagne a connu une période de croissance économique relativement forte, alimentée en partie par une augmentation de la masse monétaire. Cependant, la crise financière mondiale de 2008 a conduit à une intervention importante de la Banque d'Angleterre pour stabiliser l'économie, entraînant une expansion rapide de la masse monétaire à travers des politiques telles que l'assouplissement quantitatif.

Années 2010 : Après la crise financière, le Royaume-Uni a fait face à des défis économiques, notamment une croissance faible et une inflation modérée. La masse monétaire a continué à être influencée par les politiques de la Banque d'Angleterre, qui ont maintenu des taux d'intérêt bas et ont poursuivi des mesures d'assouplissement quantitatif.

Années 2020 : La pandémie de COVID-19 a entraîné une crise économique mondiale majeure. Pour atténuer les effets de la pandémie, la Banque d'Angleterre a mis en œuvre des mesures exceptionnelles, y compris une expansion massive de la masse monétaire par le biais de l'assouplissement quantitatif et d'autres programmes de soutien financier.

#### ❖ Pour les dépenses :

Les dépenses au Royaume-Uni ont connu plusieurs fluctuations majeures de 1972 à 2022, influencées par divers facteurs économiques, politiques et sociaux :

Années 1970 - Instabilité économique : Les années 1970 ont été marquées par une instabilité économique due à des chocs pétroliers, des tensions sociales et des politiques économiques changeantes. Les dépenses publiques ont augmenté pour faire face à des défis économiques et sociaux croissants.

Années 1980 - Politique de désengagement de l'État : Sous le gouvernement de Margaret Thatcher dans les années 1980, une politique de désengagement de l'État a été mise en œuvre, avec des réductions des dépenses publiques dans de nombreux secteurs et une privatisation accrue. Cela a conduit à des fluctuations dans les dépenses, avec des coupes dans certains domaines et des investissements dans d'autres, comme la défense et les infrastructures.

Années 1990 - Réforme de l'État et investissements ciblés : Les années 1990 ont été marquées par des réformes de l'État visant à accroître l'efficacité et à réduire les coûts. Cependant, il y a eu également des investissements ciblés dans des domaines prioritaires tels que l'éducation et la santé, ce qui a influencé les dépenses.

Années 2000 - Croissance économique et investissements sociaux : La période des années 2000 a été caractérisée par une croissance économique soutenue, ce qui a permis d'augmenter les dépenses dans des domaines tels que l'éducation, la santé et les services sociaux. Cependant, la crise financière mondiale de 2008 a eu un impact significatif, entraînant des mesures d'austérité et des compressions budgétaires dans de nombreux secteurs.

Années 2010 - Ajustements budgétaires post-crise : Au cours de la décennie précédant 2022, le Royaume-Uni a continué à faire face aux conséquences de la crise financière mondiale, avec des ajustements budgétaires, des réductions de dépenses et des efforts pour réduire le déficit public. Cependant, il y a eu également des investissements dans des domaines clés tels que l'innovation, l'infrastructure et l'éducation.

Années 2020 - Pandémie de COVID-19 : La pandémie de COVID-19 a entraîné une augmentation significative des dépenses publiques pour faire face aux conséquences sanitaires, économiques et sociales de la crise. Des mesures de soutien économique ont été mises en place, telles que des programmes de soutien aux entreprises et des aides sociales, ce qui a entraîné une forte augmentation des dépenses gouvernementales.



### 3) Etude du processus : test ADF

On a effectué le test de racines unitaires augmenté de Dickey-Fuller pour tester la stationnarité des variables et leurs degrés d'intégration.

#### a) Inflation :

Null Hypothesis: INFLATION has a unit root  
Exogenous: Constant, Linear Trend  
Lag Length: 1 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-2.809076	0.2011
Test critical values: 1% level	-4.156734	
5% level	-3.504330	
10% level	-3.181826	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(INFLATION)  
Method: Least Squares  
Date: 05/04/24 Time: 10:36  
Sample (adjusted): 1974 2022  
Included observations: 49 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
INFLATION(-1)	-0.349763	0.124512	-2.809076	0.0073
D(INFLATION(-1))	0.220222	0.153801	1.431865	0.1591
C	3.891591	1.761053	2.209809	0.0322
@TREND("1972")	-0.079915	0.044578	-1.792711	0.0797

Figure 3 - inflation trend ADF test




Figure 2 - ACF & PACF inflation

Le test montre que le TREND est non significatif puisque  $0.0797 > 0.05$ .

Essayons de refaire le test sans le trend.

Null Hypothesis: INFLATION has a unit root				
Exogenous: Constant				
Lag Length: 1 (Fixed)				
			t-Statistic	Prob.
Augmented Dickey-Fuller test statistic			-2.192364	0.2116
Test critical values:				
1% level			-3.571310	
5% level			-2.922449	
10% level			-2.599224	
*MacKinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(INFLATION)				
Method: Least Squares				
Date: 05/04/24 Time: 10:36				
Sample (adjusted): 1974 2022				
Included observations: 49 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
INFLATION(-1)	-0.177074	0.080769	-2.192364	0.0335
D(INFLATION(-1))	0.137496	0.150204	0.915395	0.3648
C	0.907849	0.589155	1.540936	0.1302

Figure 4 - inflation constante ADF test

La p-value de la constante  $0,1302 > 0,05$ , ce qui montre que la constante est non significative.  
 Passons au test suivant :

Null Hypothesis: INFLATION has a unit root				
Exogenous: None				
Lag Length: 1 (Fixed)				
			t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic			-1.538041	0.1153
Test critical values:	1% level		-2.613010	
	5% level		-1.947665	
	10% level		-1.612573	
*MacKinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(INFLATION)				
Method: Least Squares				
Date: 05/04/24 Time: 10:37				
Sample (adjusted): 1974 2022				
Included observations: 49 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
INFLATION(-1)	-0.087521	0.056904	-1.538041	0.1307
D(INFLATION(-1))	0.087170	0.148738	0.586061	0.5606

Figure 5 - inflation NONE ADF test

La p-value de l'ADF test est  $0,1153 > 0,05$ , ce qui montre que le processus inflation est non stationnaire.

Passons alors à l'étape de la différenciation : d(inflation)

On applique la différenciation du premier ordre à la variable inflation :

Null Hypothesis: DINFLATION has a unit root				
Exogenous: Constant, Linear Trend				
Lag Length: 2 (Fixed)				
			t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic			-9.113074	0.0000
Test critical values:	1% level		-4.165756	
	5% level		-3.508508	
	10% level		-3.184230	
*MacKinnon (1996) one-sided p-values.				
Augmented Dickey-Fuller Test Equation				
Dependent Variable: D(DINFLATION)				
Method: Least Squares				
Date: 05/04/24 Time: 10:58				
Sample (adjusted): 1976 2022				
Included observations: 47 after adjustments				
Variable	Coefficient	Std. Error	t-Statistic	Prob.
DINFLATION(-1)	-1.837291	0.201610	-9.113074	0.0000
D(DINFLATION(-1))	0.564150	0.150177	3.756571	0.0005
D(DINFLATION(-2))	0.354623	0.108000	3.283532	0.0021
C	-2.280861	0.690572	-3.302857	0.0020
@TREND("1972")	0.065887	0.022734	2.898199	0.0059

Figure 6- d(inflation) trend ADF test

On peut remarquer que la série en différence première : d(inflation) est bien stationnaire  
P-value = 0 < 0,05 mais le trend est non significatif donc on passe aux tests suivants :

Null Hypothesis: DINFLATION has a unit root  
Exogenous: Constant  
Lag Length: 1 (Automatic - based on SIC, maxlag=10)

	t-Statistic	Prob. *
Augmented Dickey-Fuller test statistic	-5.760051	0.0000
Test critical values: 1% level	-3.574446	
5% level	-2.923780	
10% level	-2.599925	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DINFLATION)  
Method: Least Squares  
Date: 05/09/24 Time: 20:30  
Sample (adjusted): 1975 2022  
Included observations: 48 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DINFLATION(-1)	-1.152124	0.200020	-5.760051	0.0000
D(DINFLATION(-1))	0.164758	0.143047	1.151771	0.2555
C	-0.188325	0.408186	-0.461369	0.6468

R-squared	0.521872	Mean dependent var	-0.030090
Adjusted R-squared	0.500622	S.D. dependent var	3.993365
S.E. of regression	2.821979	Akaike info criterion	4.973215
Sum squared resid	358.3604	Schwarz criterion	5.090165
Log likelihood	-116.3572	Hannan-Quinn criter.	5.017411
F-statistic	24.55853	Durbin-Watson stat	2.160401
Prob(F-statistic)	0.000000		

Null Hypothesis: DINFLATION has a unit root  
Exogenous: None  
Lag Length: 1 (Automatic - based on SIC, maxlag=10)

	t-Statistic	Prob. *
Augmented Dickey-Fuller test statistic	-5.791962	0.0000
Test critical values: 1% level	-2.614029	
5% level	-1.947816	
10% level	-1.612492	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DINFLATION)  
Method: Least Squares  
Date: 05/09/24 Time: 20:31  
Sample (adjusted): 1975 2022  
Included observations: 48 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DINFLATION(-1)	-1.146113	0.197880	-5.791962	0.0000
D(DINFLATION(-1))	0.161909	0.141686	1.142732	0.2591

R-squared	0.519610	Mean dependent var	-0.030090
Adjusted R-squared	0.509167	S.D. dependent var	3.993365
S.E. of regression	2.797730	Akaike info criterion	4.936268
Sum squared resid	360.0556	Schwarz criterion	5.014234
Log likelihood	-116.4704	Hannan-Quinn criter.	4.965731
Durbin-Watson stat	2.155033		

Finalement la constante n'est pas significative aussi p-value = 64% > 5%

- Estimation des coefficients :

Dependent Variable: D(INFLATION)  
Method: ARMA Maximum Likelihood (OPG - BHHH)  
Date: 05/07/24 Time: 20:59  
Sample: 1973 2022  
Included observations: 50  
Convergence achieved after 14 iterations  
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
MA(3)	-0.448520	0.139166	-3.222926	0.0023
SIGMASQ	7.238078	1.030848	7.021478	0.0000
R-squared	0.141843	Mean dependent var		0.017019
Adjusted R-squared	0.123965	S.D. dependent var		2.933697
S.E. of regression	2.745845	Akaike info criterion		4.910709
Sum squared resid	361.9039	Schwarz criterion		4.987190
Log likelihood	-120.7677	Hannan-Quinn criter.		4.939834
Durbin-Watson stat	2.016447			
Inverted MA Roots	.77	-.38+.66i	-.38-.66i	

Figure 7 - d(inflation) estimation coef

Finalement notre processus d(inflation) peut être modélisé par le processus MA (3).

## b) Masse monétaire :

Null Hypothesis: MASSE has a unit root  
Exogenous: Constant, Linear Trend  
Lag Length: 1 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-3.041095	0.1320
Test critical values: 1% level	-4.156734	
5% level	-3.504330	
10% level	-3.181826	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(MASSE)  
Method: Least Squares  
Date: 05/04/24 Time: 10:40  
Sample (adjusted): 1974 2022  
Included observations: 49 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
MASSE(-1)	-0.228721	0.075210	-3.041095	0.0039
D(MASSE(-1))	0.346988	0.135739	2.556283	0.0140
C	3.239236	2.465303	1.313930	0.1955
@TREND("1972")	0.734895	0.241917	3.037794	0.0040

Figure 8 masse monétaire trend ADF test




Figure 9 ACF & PACF masse monétaire

Le test montre que le TREND est bien significatif puisque  $0.004 < 0.05$ , mais la série masse monétaire est non stationnaire car le p-value est  $0.1320 > 0.05$

On va commencer donc par une différence première :

Null Hypothesis: DMASSE has a unit root  
Exogenous: Constant, Linear Trend  
Lag Length: 1 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-3.870952	0.0211
Test critical values: 1% level	-4.161144	
5% level	-3.506374	
10% level	-3.183002	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DMASSE)  
Method: Least Squares  
Date: 05/04/24 Time: 11:02  
Sample (adjusted): 1975 2022  
Included observations: 48 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DMASSE(-1)	-0.718180	0.185531	-3.870952	0.0004
D(DMASSE(-1))	-0.040341	0.151105	-0.266976	0.7907
C	0.924820	2.694201	0.343263	0.7330
@TREND("1972")	0.033195	0.090879	0.365268	0.7167

Figure 10 - d(masse) ADF trend test

On peut remarquer que la série en différence première : d(masse) est bien stationnaire P-value =  $0.0211 < 0.05$  mais le trend est non significatif donc on passe au test suivant pour tester la constante.

Null Hypothesis: DMASSE has a unit root  
Exogenous: Constant  
Lag Length: 0 (Automatic - based on SIC, maxlag=10)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-5.259088	0.0001
Test critical values: 1% level	-3.571310	
5% level	-2.922449	
10% level	-2.599224	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DMASSE)  
Method: Least Squares  
Date: 05/09/24 Time: 18:55  
Sample (adjusted): 1974 2022  
Included observations: 49 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DMASSE(-1)	-0.743161	0.141310	-5.259088	0.0000
C	1.817136	1.252976	1.450256	0.1536
R-squared	0.370463	Mean dependent var	-0.115684	
Adjusted R-squared	0.357068	S.D. dependent var	10.45738	
S.E. of regression	8.385047	Akaike info criterion	7.130737	
Sum squared resid	3304.524	Schwarz criterion	7.207954	
Log likelihood	-172.7031	Hannan-Quinn criter.	7.160033	
F-statistic	27.65800	Durbin-Watson stat	2.014104	
Prob(F-statistic)	0.000003			

Null Hypothesis: DMASSE has a unit root  
Exogenous: None  
Lag Length: 0 (Automatic - based on SIC, maxlag=10)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-4.998972	0.0000
Test critical values: 1% level	-2.613010	
5% level	-1.947665	
10% level	-1.612573	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DMASSE)  
Method: Least Squares  
Date: 05/09/24 Time: 18:54  
Sample (adjusted): 1974 2022  
Included observations: 49 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DMASSE(-1)	-0.683050	0.136638	-4.998972	0.0000
R-squared	0.342291	Mean dependent var	-0.115684	
Adjusted R-squared	0.342291	S.D. dependent var	10.45738	
S.E. of regression	8.480861	Akaike info criterion	7.133698	
Sum squared resid	3452.400	Schwarz criterion	7.172307	
Log likelihood	-173.7756	Hannan-Quinn criter.	7.148346	
Durbin-Watson stat	2.052977			

Finalement la constante n'est pas significative aussi p-value = 15% > 5%

Enfin cette variable peut être modélisé par le processus ARIMA (p, 1, q) ; Avec max (p, q) = (1,4)

- Estimation des coefficients :

Dependent Variable: D(MASSE)  
Method: ARMA Maximum Likelihood (OPG - BHHH)  
Date: 05/07/24 Time: 21:34  
Sample: 1973 2022  
Included observations: 50  
Convergence achieved after 7 iterations  
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	0.312014	0.145792	2.140135	0.0375
SIGMASQ	69.33643	8.273517	8.380527	0.0000
R-squared	0.020393	Mean dependent var	2.515101	
Adjusted R-squared	-0.000016	S.D. dependent var	8.498489	
S.E. of regression	8.498556	Akaike info criterion	7.158896	
Sum squared resid	3466.822	Schwarz criterion	7.235377	
Log likelihood	-176.9724	Hannan-Quinn criter.	7.188020	
Durbin-Watson stat	2.040310			
Inverted AR Roots	.31			

Figure 11 - d(masse) estimation coef

Finalement notre processus d(masse) peut être modélisé par le processus ARMA (1, 0).

### c) Dépense :

Null Hypothesis: DEPENSE has a unit root  
Exogenous: Constant, Linear Trend  
Lag Length: 1 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-3.049836	0.1298
Test critical values: 1% level	-4.156734	
5% level	-3.504330	
10% level	-3.181826	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DEPENSE)  
Method: Least Squares  
Date: 05/04/24 Time: 10:32  
Sample (adjusted): 1974 2022  
Included observations: 49 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DEPENSE(-1)	-0.361021	0.118374	-3.049836	0.0038
D(DEPENSE(-1))	0.112782	0.147590	0.764156	0.4488
C	12.08730	3.893925	3.104144	0.0033
@TREND("1972")	0.059103	0.029105	2.030661	0.0482

Figure 13 - dépense trend ADF test




Figure 12 - PACF & ACF dépense

Le test montre que le TREND est bien significatif puisque  $0.0482 < 0.05$ , mais la série masse dépense est non stationnaire car le p-value est  $0.1298 > 0.05$

On va commencer donc par une différence première :

Null Hypothesis: DDEPENSE has a unit root  
Exogenous: Constant, Linear Trend  
Lag Length: 1 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-4.447215	0.0046
Test critical values: 1% level	-4.161144	
5% level	-3.506374	
10% level	-3.183002	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DDEPENSE)  
Method: Least Squares  
Date: 05/04/24 Time: 10:51  
Sample (adjusted): 1975 2022  
Included observations: 48 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DDEPENSE(-1)	-0.952320	0.214138	-4.447215	0.0001
D(DDEPENSE(-1))	-0.092105	0.150673	-0.611294	0.5442
C	-0.012147	0.708285	-0.017150	0.9864
@TREND("1972")	0.008897	0.023655	0.376087	0.7087

Figure 14 - d(depense) trend ADF test

On peut remarquer que la série en différence première : d(depense) est bien stationnaire P-value =  $0.0046 < 0.05$  mais le trend n'est pas significatif donc on passe au test suivant pour tester la significativité de la constante.

Null Hypothesis: DDEPENDSE has a unit root  
Exogenous: Constant  
Lag Length: 0 (Automatic - based on SIC, maxlag=10)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-7.325448	0.0000
Test critical values:		
1% level	-3.571310	
5% level	-2.922449	
10% level	-2.599224	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DDEPENDSE)  
Method: Least Squares  
Date: 05/09/24 Time: 19:02  
Sample (adjusted): 1974 2022  
Included observations: 49 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DDEPENDSE(-1)	-1.066230	0.145551	-7.325448	0.0000
C	0.349006	0.328954	1.060958	0.2941
R-squared	0.533092	Mean dependent var	0.040375	
Adjusted R-squared	0.523158	S.D. dependent var	3.307150	
S.E. of regression	2.283712	Akaike info criterion	4.529441	
Sum squared resid	245.1210	Schwarz criterion	4.606659	
Log likelihood	-108.9713	Hannan-Quinn criter.	4.558738	
F-statistic	53.66218	Durbin-Watson stat	1.887669	
Prob(F-statistic)	0.000000			

Null Hypothesis: DDEPENDSE has a unit root  
Exogenous: None  
Lag Length: 0 (Automatic - based on SIC, maxlag=10)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-7.239798	0.0000
Test critical values:		
1% level	-2.613010	
5% level	-1.947665	
10% level	-1.612573	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(DDEPENDSE)  
Method: Least Squares  
Date: 05/09/24 Time: 19:02  
Sample (adjusted): 1974 2022  
Included observations: 49 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DDEPENDSE(-1)	-1.046452	0.144542	-7.239798	0.0000
R-squared	0.521910	Mean dependent var	0.040375	
Adjusted R-squared	0.521910	S.D. dependent var	3.307150	
S.E. of regression	2.286699	Akaike info criterion	4.512292	
Sum squared resid	250.9916	Schwarz criterion	4.550901	
Log likelihood	-109.5512	Hannan-Quinn criter.	4.526940	
Durbin-Watson stat	1.885077			

Finalement la constante n'est pas significative aussi p-value = 29% > 5%

- Estimation des coefficients :

Dependent Variable: D(DEPENSE)  
Method: ARMA Maximum Likelihood (OPG - BHHH)  
Date: 05/07/24 Time: 21:42  
Sample: 1973 2022  
Included observations: 50  
Convergence achieved after 32 iterations  
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
AR(1)	-0.985966	0.117891	-8.363404	0.0000
MA(1)	0.938741	0.244916	3.832916	0.0004
SIGMASQ	4.798336	0.477306	10.05295	0.0000
R-squared	0.029415	Mean dependent var	0.309763	
Adjusted R-squared	-0.011886	S.D. dependent var	2.246030	
S.E. of regression	2.259339	Akaike info criterion	4.536433	
Sum squared resid	239.9168	Schwarz criterion	4.651155	
Log likelihood	-110.4108	Hannan-Quinn criter.	4.580120	
Durbin-Watson stat	1.904732			
Inverted AR Roots	-.99			
Inverted MA Roots	-.94			

Figure 15 - d(depense) estimation coef

Finalement notre processus d(depense) peut être modélisé par le processus ARMA (1, 1).



## d) Croissance :

Null Hypothesis: CROISSANCE has a unit root  
Exogenous: Constant, Linear Trend  
Lag Length: 2 (Fixed)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-4.387726	0.0054
Test critical values: 1% level	-4.161144	
5% level	-3.506374	
10% level	-3.183002	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(CROISSANCE)  
Method: Least Squares  
Date: 05/04/24 Time: 10:29  
Sample (adjusted): 1975 2022  
Included observations: 48 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
CROISSANCE(-1)	-1.241843	0.283027	-4.387726	0.0001
D(CROISSANCE(-1))	0.259489	0.227456	1.140830	0.2603
D(CROISSANCE(-2))	0.151662	0.204786	0.740587	0.4630
C	3.294513	1.172689	2.809367	0.0074
@TREND("1972")	-0.025745	0.030991	-0.830716	0.4107

Figure 17 - croissance ADF trend test




Figure 16 - ACF & PACF croissance

Le test montre que cette série est bien stationnaire puisque  $P\text{-value} = 0.0054 < 0.05$  mais le trend est non significatif donc on passe pour tester la significativité de la constante.

Null Hypothesis: CROISSANCE has a unit root  
Exogenous: Constant  
Lag Length: 0 (Automatic - based on SIC, maxlag=10)

	t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic	-6.842390	0.0000
Test critical values: 1% level	-3.568308	
5% level	-2.921175	
10% level	-2.598551	

\*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation  
Dependent Variable: D(CROISSANCE)  
Method: Least Squares  
Date: 05/09/24 Time: 19:05  
Sample (adjusted): 1973 2022  
Included observations: 50 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
CROISSANCE(-1)	-0.987671	0.144346	-6.842390	0.0000
C	2.074046	0.514486	4.031296	0.0002
R-squared	0.493769	Mean dependent var		0.000498
Adjusted R-squared	0.483222	S.D. dependent var		4.089596
S.E. of regression	2.939899	Akaike info criterion		5.033805
Sum squared resid	414.8642	Schwarz criterion		5.110286
Log likelihood	-123.8451	Hannan-Quinn criter.		5.062930
F-statistic	46.81831	Durbin-Watson stat		1.986173
Prob(F-statistic)	0.000000			

Finalement on a obtenu que la constante est bien significative avec un  $p\text{-value} = 0.0002 < 5\%$

Le processus de croissance est finalement stationnaire native avec une constante significative.



- Estimation des coefficients :

Dependent Variable: CROISSANCE  
Method: ARMA Maximum Likelihood (OPG - BHHH)  
Date: 05/07/24 Time: 21:52  
Sample: 1972 2022  
Included observations: 51  
Convergence achieved after 30 iterations  
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
MA(1)	0.291417	0.125700	2.318352	0.0246
SIGMASQ	11.55444	2.328909	4.961311	0.0000
R-squared	-0.403820	Mean dependent var		2.143492
Adjusted R-squared	-0.432469	S.D. dependent var		2.897470
S.E. of regression	3.467860	Akaike info criterion		5.365119
Sum squared resid	589.2766	Schwarz criterion		5.440876
Log likelihood	-134.8105	Hannan-Quinn criter.		5.394068
Durbin-Watson stat	1.889356			
Inverted MA Roots	-.29			

Figure 18 - croissance estimation coef

Finalement notre processus croissance peut être modélisé par le processus MA (1).

## II. Modélisation VAR :

### 1) Détermination du lag optimal et tests de diagnostiques :

#### a) Estimation du VAR :

Notre modèle comprend trois variables (Inflation, Masse monétaire, dépense).

On peut traduire le modèle par l'équation suivante :

$$Z_t = \begin{pmatrix} d(Inf)_t \\ d(Mon)_t \\ d(Dep)_t \\ Croi_t \end{pmatrix} = \alpha + \sum_{i=1}^p \beta_i \begin{pmatrix} d(Inf)_{t-i} \\ d(Mon)_{t-i} \\ d(Dep)_{t-i} \\ Croi_{t-i} \end{pmatrix} + \varepsilon_t$$

Avec :

- $Z_t$  Est un vecteur de dimension 3
- $d(Inf)_t$  Est le taux d'inflation à l'année t qui est stationnaire en différence première.
- $d(Mon)_t$  Est la masse monétaire à l'année t qui est stationnaire en différence première.
- $d(Dep)_t$  Est la dépense à l'année t qui est stationnaire en différence première.
- $Croi_t$  Est la dépense à l'année t qui est stationnaire en niveau.
- $\alpha$  Est un vecteur de dimension 4 qui représente la constante.
- $\beta_i$  Est une matrice ( $4 \times 4$ ) qui représente les variables du modèle.
- $\varepsilon_t$  Est un vecteur des résidus

Vector Autoregression Estimates				
Date: 05/04/24 Time: 11:06				
Sample (adjusted): 1975 2022				
Included observations: 48 after adjustments				
Standard errors in ( ) & t-statistics in [ ]				
	CROISSANCE	DDEPENSE	DINFLATION	DMASSE
CROISSANCE(-1)	0.102083 (0.29587) [ 0.34502]	-0.112020 (0.22753) [-0.49234]	0.551352 (0.29385) [ 1.87632]	0.568610 (0.90504) [ 0.62827]
CROISSANCE(-2)	-0.094417 (0.30016) [-0.31456]	0.336951 (0.23082) [ 1.45981]	0.235697 (0.29810) [ 0.79066]	0.849723 (0.91814) [ 0.92548]
DDEPENSE(-1)	0.122148 (0.37221) [ 0.32817]	-0.119307 (0.28623) [-0.41682]	0.623236 (0.36966) [ 1.68595]	-0.211713 (1.13855) [-0.18595]
DDEPENSE(-2)	0.097848 (0.37494) [ 0.26097]	0.377533 (0.28832) [ 1.30941]	0.188554 (0.37237) [ 0.50637]	0.055420 (1.14688) [ 0.04832]
DINFLATION(-1)	-0.218682 (0.15883) [-1.37681]	0.117269 (0.12214) [ 0.96011]	-0.043845 (0.15774) [-0.27795]	-0.316000 (0.48584) [-0.65041]
DINFLATION(-2)	-0.107412 (0.15374) [-0.69866]	0.008338 (0.11822) [ 0.07052]	-0.134752 (0.15269) [-0.88254]	0.308746 (0.47027) [ 0.65653]

DMASSE(-1)	0.096006 (0.05265) [ 1.82360]	-0.064152 (0.04048) [-1.58459]	0.023209 (0.05229) [ 0.44388]	0.224363 (0.16104) [ 1.39322]
DMASSE(-2)	-0.052284 (0.05362) [-0.97510]	0.054017 (0.04123) [ 1.31005]	0.045494 (0.05325) [ 0.85433]	0.026132 (0.16401) [ 0.15933]
C	1.855070 (1.05021) [ 1.76638]	-0.246236 (0.80761) [-0.30490]	-2.168235 (1.04302) [-2.07881]	-0.817789 (3.21245) [-0.25457]
R-squared	0.174400	0.202480	0.173780	0.181232
Adj. R-squared	0.005046	0.038886	0.004299	0.013280
Sum sq. resids	309.0548	182.7600	304.8358	2891.725
S.E. equation	2.815045	2.164753	2.795765	8.610853
F-statistic	1.029796	1.237700	1.025365	1.079071
Log likelihood	-112.8047	-100.1964	-112.4748	-166.4708
Akaike AIC	5.075195	4.549850	5.061449	7.311285
Schwarz SC	5.426045	4.900700	5.412300	7.662135
Mean dependent	2.103271	0.244717	-0.169208	2.531171
S.D. dependent	2.822175	2.208111	2.801794	8.668606
Determinant resid covariance (dof adj.)	5417.457			
Determinant resid covariance	2360.962			
Log likelihood	-458.8400			
Akaike information criterion	20.61833			
Schwarz criterion	22.02173			
Number of coefficients	36			

Figure 19 – VAR (2) estimé

## b) Vérification de la stationnarité du processus :

Nous allons visualiser graphiquement l'inverse des racines associée à la partie AR(.) de chacune des deux variables inflation, masse monétaire et dépense :




Figure 20 cercle racine unitaire

L'inverse des racines unitaires appartiennent au disque unité complexe. Aussi, le module de toutes les racines est inférieur à 1 et très proche de 0, par suite, le processus  $Z_t \sim \text{VAR}(1)$  est bien stationnaire.

Passant en 2<sup>ème</sup> étape à la détermination du lag optimal du VAR :

VAR Lag Order Selection Criteria  
 Endogenous variables: CROISSANCE DDEPENSE DINFLATION DMASSE  
 Exogenous variables: C  
 Date: 05/04/24 Time: 11:06  
 Sample: 1972 2022  
 Included observations: 46

Lag	LogL	LR	FPE	AIC	SC	HQ
0	-452.5124	NA*	4899.478*	19.84836*	20.00738*	19.90793*
1	-441.4638	19.69534	6097.192	20.06364	20.85870	20.36148
2	-431.0506	16.75161	7906.847	20.30655	21.73766	20.84265
3	-415.7879	21.89864	8521.500	20.33861	22.40577	21.11298
4	-408.2624	9.488774	13391.62	20.70706	23.41027	21.71970

\* indicates lag order selected by the criterion  
 LR: sequential modified LR test statistic (each test at 5% level)  
 FPE: Final prediction error  
 AIC: Akaike information criterion  
 SC: Schwarz information criterion  
 HQ: Hannan-Quinn information criterion

Figure 21 ordre du lag

La longueur de retard optimale du VAR estimé(.) qui minimise les statistiques LR, FPE et AIC est de 1. Les tests d'exclusion de Wald pour le VAR à retard sont utilisés pour déterminer l'ordre de retard approprié pour un modèle VAR.

Dans ce cas, nous avons trois variables : l'inflation, dépense, croissance et la masse monétaire, et nous testons si nous devons inclure jusqu'à 1 retards pour chaque variable dans le modèle.

VAR Lag Exclusion Wald Tests  
 Date: 05/07/24 Time: 13:05  
 Sample (adjusted): 1975 2022  
 Included observations: 48 after adjustments

Chi-squared test statistics for lag exclusion:  
 Numbers in [ ] are p-values

	CROISSANCE	DDEPENSE	DMASSE	DINFLATION	Joint
Lag 1	6.093606 [ 0.1923]	4.281437 [ 0.3693]	4.567439 [ 0.3346]	4.294936 [ 0.3676]	18.03968 [ 0.3216]
Lag 2	2.307240 [ 0.6795]	4.291848 [ 0.3679]	3.051816 [ 0.5492]	2.164147 [ 0.7056]	19.54402 [ 0.2415]
df	4	4	4	4	16

Figure 22 test Wald pour les Lags

Les résultats n'indiquent pas un retard significatif.

Finalement on va choisir par « intuition » un lag égale à 1.

Finalement le VAR à un seul lag sera :

Vector Autoregression Estimates				
Date: 05/04/24 Time: 11:09				
Sample (adjusted): 1974 2022				
Included observations: 49 after adjustments				
Standard errors in ( ) & t-statistics in [ ]				
	CROISSANCE	DDEPENSE	DINFLATION	DMASSE
CROISSANCE(-1)	-0.041235 (0.27248) [-0.15133]	0.050780 (0.21597) [0.23512]	0.745594 (0.27119) [2.74937]	0.289540 (0.82256) [0.35200]
DDEPENSE(-1)	-0.011656 (0.35505) [-0.03283]	-0.018433 (0.28142) [-0.06550]	0.715186 (0.35336) [2.02394]	-0.424100 (1.07181) [-0.39568]
DINFLATION(-1)	-0.293573 (0.14237) [-2.06207]	0.243822 (0.11284) [2.16070]	0.062222 (0.14169) [0.43913]	-0.193955 (0.42978) [-0.45129]
DMASSE(-1)	0.076102 (0.04834) [1.57417]	-0.046243 (0.03832) [-1.20682]	0.045431 (0.04811) [0.94421]	0.282531 (0.14594) [1.93593]
C	1.872514 (0.75496) [2.48030]	0.373789 (0.59839) [0.62465]	-1.876902 (0.75138) [-2.49796]	1.260317 (2.27905) [0.55300]
R-squared	0.128813	0.121985	0.183041	0.113423
Adj. R-squared	0.049614	0.042165	0.108772	0.032825
Sum sq. resids	344.0813	216.1681	340.8257	3135.636
S.E. equation	2.796432	2.216509	2.783171	8.441827
F-statistic	1.626445	1.528258	2.464569	1.407272
Log likelihood	-117.2799	-105.8918	-117.0470	-171.4178
Akaike AIC	4.991017	4.526195	4.981510	7.200726
Schwarz SC	5.184059	4.719237	5.174552	7.393768
Mean dependent	2.009645	0.329835	-0.026000	2.485123
S.D. dependent	2.868495	2.264770	2.948122	8.583887
Determinant resid covariance (dof adj.)	5903.171			
Determinant resid covariance	3838.060			
Log likelihood	-480.3036			
Akaike information criterion	20.42056			
Schwarz criterion	21.19273			
Number of coefficients	20			

Figure 23 – VAR (1) estimé

### c) Test de causalité :

Les résultats de ce test dans notre cas se présentent comme suit :

#### VAR Granger Causality/Block Exogeneity Wald Tests

Date: 05/07/24 Time: 22:23

Sample: 1972 2022

Included observations: 48

#### Dependent variable: CROISSANCE

Excluded	Chi-sq	df	Prob.
DDEPENSE	0.172390	2	0.9174
DINFLATION	2.332114	2	0.3116
DMASSE	3.515960	2	0.1724
All	7.607674	6	0.2683

#### Dependent variable: DDEPENSE

Excluded	Chi-sq	df	Prob.
CROISSANCE	2.416702	2	0.2987
DINFLATION	0.923743	2	0.6301
DMASSE	3.259883	2	0.1959
All	9.325479	6	0.1561

#### Dependent variable: DINFLATION

Excluded	Chi-sq	df	Prob.
CROISSANCE	4.063902	2	0.1311
DDEPENSE	3.065388	2	0.2160
DMASSE	1.280365	2	0.5272
All	6.847816	6	0.3352

#### Dependent variable: DMASSE

Excluded	Chi-sq	df	Prob.
CROISSANCE	1.218863	2	0.5437
DDEPENSE	0.037293	2	0.9815
DINFLATION	0.878468	2	0.6445
All	5.386703	6	0.4953

Figure 24 - test de causalité Granger

Selon les résultats du test de causalité de Granger, il est suggéré que :

- Les variables  $d(\text{depense})$ ,  $d(\text{inflation})$  et  $d(\text{masse})$  n'ont pas une influence significative sur la croissance, avec des p valeurs respectivement de 0.9174, 0.116, 0.1724 qui sont supérieurs au seuil de significativité de 0,05.
- Les variables  $d(\text{depense})$ , croissance et  $d(\text{masse})$  n'ont pas une influence significative sur la croissance, avec des p valeurs respectivement de 0.1311, 0.216, 0.5272 qui sont supérieurs au seuil de significativité de 0,05.
- Les variables  $d(\text{inflation})$ , croissance et  $d(\text{masse})$  n'ont pas une influence significative sur la croissance, avec des p valeurs respectivement de 0.2987, 0.6301, 0.1959 qui sont supérieurs au seuil de significativité de 0,05.
- Les variables  $d(\text{depense})$ , croissance et  $d(\text{inflation})$  n'ont pas une influence significative sur la croissance, avec des p valeurs respectivement de 0.5437, 0.9815, 0.6445 qui sont supérieurs au seuil de significativité de 0,05.

Ces résultats suggèrent qu'il n'y a pas une forte relation de causalité significative entre ces différentes variables.

## 2) Diagnostique du VAR estimé :

### a) Résultat sous forme d'équation :

- Le modèle VAR estimé :

$$\text{croissance}_t = -0.041 \text{croissance}_{t-1} - 0.011 \Delta \text{depense}_{t-1} - 0.293 \Delta \text{inflation}_{t-1} + 0.076 \Delta \text{masse}_{t-1} + 1.872$$

$$\Delta \text{depense}_t = 0.05 \text{croissance}_{t-1} - 0.018 \Delta \text{depense}_{t-1} + 0.243 \Delta \text{inflation}_{t-1} - 0.046 \Delta \text{masse}_{t-1} + 0.3737$$

$$\Delta \text{inflation}_t = 0.745 \text{croissance}_{t-1} + 0.715 \Delta \text{depense}_{t-1} + 0.062 \Delta \text{inflation}_{t-1} + 0.045 \Delta \text{masse}_{t-1} - 1.876$$

$$\Delta \text{masse}_t = 0.289 \text{croissance}_{t-1} - 0.424 \Delta \text{depense}_{t-1} - 0.193 \Delta \text{inflation}_{t-1} + 0.282 \Delta \text{masse}_{t-1} + 1.26$$

### b) Tests post-estimation :

- Test d'autocorrélations de Portmanteau :

VAR Residual Portmanteau Tests for Autocorrelations  
Null Hypothesis: No residual autocorrelations up to lag h  
Date: 05/07/24 Time: 23:40  
Sample: 1972 2022  
Included observations: 48

Lags	Q-Stat	Prob.*	Adj Q-Stat	Prob.*	df
1	2.995274	---	3.059003	---	---
2	9.748648	---	10.10600	---	---
3	21.59632	0.1567	22.74352	0.1208	16
4	27.09676	0.7132	28.74399	0.6321	32
5	52.88358	0.2912	57.52928	0.1631	48

\*Test is valid only for lags larger than the VAR lag order.  
df is degrees of freedom for (approximate) chi-square distribution

Figure 25 - Test d'autocorrélations de Portmanteau

Les résultats du test d'exclusion de lag montrent que pour les lags 1 et 2, les statistiques Q-Stat sont inférieures aux valeurs critiques, ce qui indique qu'il n'y a pas suffisamment de preuves pour rejeter l'hypothèse nulle selon laquelle il n'y a pas d'autocorrélation résiduelle jusqu'à ces lags. Par conséquent, cela confirme que le modèle VAR est correctement spécifié et qu'il n'y a pas d'autocorrélations résiduelles significatives jusqu'au lag 2.

- Test d'hétéroscédasticité :

VAR Residual Heteroskedasticity Tests (Levels and Squares)

Date: 05/07/24 Time: 23:33

Sample: 1972 2022

Included observations: 48

Joint test:

Chi-sq	df	Prob.
190.3827	160	0.0507

Individual components:

Dependent	R-squared	F(16,31)	Prob.	Chi-sq(16)	Prob.
res1*res1	0.105395	0.228260	0.9985	5.058961	0.9955
res2*res2	0.097896	0.210257	0.9991	4.699015	0.9971
res3*res3	0.643875	3.503010	0.0014	30.90601	0.0138
res4*res4	0.198749	0.480594	0.9384	9.539962	0.8895
res2*res1	0.098460	0.211601	0.9991	4.726088	0.9970
res3*res1	0.601854	2.928803	0.0050	28.88898	0.0247
res3*res2	0.466372	1.693309	0.1019	22.38587	0.1312
res4*res1	0.099970	0.215206	0.9990	4.798561	0.9967
res4*res2	0.098336	0.211306	0.9991	4.720141	0.9970
res4*res3	0.633952	3.355526	0.0019	30.42971	0.0159

Figure 26 - Test d'hétéroscédasticité

On remarque une p-value de 0,0507 ce qui nous informe qu'il y a des preuves qui nous permettent d'accepter l'hypothèse nulle d'absence d'hétéroscédasticité résiduelle significative pour l'ensemble des variables.



### 3) Cointégration :

Le test de cointégration VAR (Vector Autoregressive) est une méthode qui utilise un modèle VAR pour déterminer si deux ou plusieurs variables ont une relation de long terme stable et significative. Le modèle VAR est un outil statistique qui permet de modéliser la dynamique de plusieurs séries chronologiques en même temps, ce qui permet d'examiner les relations entre ces séries.

Les résultats relatifs à ce test se présentent comme suit :

Date: 05/04/24 Time: 11:11 Sample (adjusted): 1975 2022 Included observations: 48 after adjustments Trend assumption: No deterministic trend (restricted constant) Series: CROISSANCE DDEPENSE DINFLATION DMASSE Lags interval (in first differences): 1 to 1					CROISSANCE -0.359638 0.458089 -0.181032 -0.856572	DDEPENSE -0.228422 -0.021299 -0.553593 -1.168660	DINFLATION 0.453983 0.281901 0.132157 -0.031202	DMASSE -0.005248 -0.085985 0.125002 -0.025524	C 0.873011 -0.675836 0.176332 2.137051
Unrestricted Cointegration Rank Test (Trace)					Unrestricted Adjustment Coefficients (alpha):				
Hypothesized No. of CE(s)	Eigenvalue	Trace Statistic	0.05 Critical Value	Prob.**	D(CROISSA...	0.637939	-1.783761	-0.827644	0.111627
					D(DDEPENSE)	-0.560354	1.060791	0.704914	0.390997
					D(DINFLATI...	-2.288494	-0.538246	0.031725	-0.252551
					D(DMASSE)	-1.529657	4.011379	-2.942802	1.753614
None *	0.478971	83.85324	54.07904	0.0000	1 Cointegrating Equation(s): Log likelihood -485.1198				
At most 1 *	0.438467	52.55965	35.19275	0.0003	Normalized cointegrating coefficients (standard error in parentheses)				
At most 2 *	0.268478	24.85959	20.26184	0.0108	CROISSANCE	1.000000	0.635145	-1.262334	0.014593
At most 3 *	0.185581	9.853448	9.164546	0.0370		(0.30690)	(0.24358)	(0.06618)	(0.49242)
Trace test indicates 4 cointegrating eqn(s) at the 0.05 level					Adjustment coefficients (standard error in parentheses)				
* denotes rejection of the hypothesis at the 0.05 level					D(CROISSA...	-0.229427			
**MacKinnon-Haug-Michelis (1999) p-values						(0.17617)			
Unrestricted Cointegration Rank Test (Maximum Eigenvalue)					D(DDEPENSE)	0.201525			
Hypothesized No. of CE(s)	Eigenvalue	Max-Eigen Statistic	0.05 Critical Value	Prob.**		(0.12958)			
					D(DINFLATI...	0.823029			
						(0.14202)			
None *	0.478971	31.29359	28.58808	0.0220	D(DMASSE)	0.550122			
At most 1 *	0.438467	27.70007	22.29962	0.0080		(0.51469)			
At most 2 *	0.268478	15.00614	15.89210	0.0685	2 Cointegrating Equation(s): Log likelihood -471.2698				
At most 3 *	0.185581	9.853448	9.164546	0.0370	Normalized cointegrating coefficients (standard error in parentheses)				
Max-eigenvalue test indicates 2 cointegrating eqn(s) at the 0.05 level									
* denotes rejection of the hypothesis at the 0.05 level									
**MacKinnon-Haug-Michelis (1999) p-values									
Unrestricted Cointegrating Coefficients (normalized by b**S11*b=l):									

D'après les résultats ci-dessus, il y a 4 équations de cointégration à un niveau de confiance de 0,05, ce qui signifie qu'il existe une relation de long terme entre les variables. Les coefficients de cointégration normalisés indiquent que pour chaque augmentation d'une unité de croissance :

- La d(depense) augmente de 0,635.
- La d(inflation) diminue de 1.26.
- La d(masse) augmente de 0.014.

Les coefficients d'ajustement indiquent que pour ajuster la relation de cointégration :

- La variable d(croissance) doit être multipliée par -0.22
- La variable d<sup>2</sup>(depense) doit être multipliée par 0.20
- La variable d<sup>2</sup>(inflation) doit être multipliée par 0.82
- La variable d<sup>2</sup>(masse) doit être multipliée par 0.55



En conclusion, les résultats suggèrent qu'il existe une relation de long terme significative entre l'inflation et la masse monétaire, et que cette relation peut être ajustée en utilisant les coefficients d'ajustement estimés qui présente comme suit

$$\text{Croissance} = -0.359 \cdot \text{Croissance} - 0.228 \Delta(\text{depense}) + 0.453 \Delta(\text{inflation}) - 0.005 \Delta(\text{masse}) + 0.87$$

$$\Delta(\text{depense}) = 0.458 \cdot \text{Croissance} - 0.021 \Delta(\text{depense}) + 0.281 \Delta(\text{inflation}) - 0.085 \Delta(\text{masse}) - 0.675$$

$$\Delta(\text{inflation}) = -0.181 \cdot \text{Croissance} - 0.553 \Delta(\text{depense}) + 0.132 \Delta(\text{inflation}) - 0.125 \Delta(\text{masse}) + 0.176$$

$$\Delta(\text{masse}) = -0.856 \cdot \text{Croissance} - 1.168 \Delta(\text{depense}) - 0.031 \Delta(\text{inflation}) - 0.025 \Delta(\text{masse}) + 2.137$$


#### 4) Fonctions de réponses impulsionnelles et Structure Dynamique du processus VAR :

a) Analyse graphique des fonctions de réponse impulsionnelle :

Response of CROISSANCE:				
Period	CROISSA...	DDEPENDSE	DINFLATION	DMASSE
1	2.815045 (0.28731)	0.000000 (0.00000)	0.000000 (0.00000)	0.000000 (0.00000)
2	0.000884 (0.46538)	0.358527 (0.44127)	-0.662274 (0.46116)	0.791436 (0.44145)
3	-0.275284 (0.45974)	-0.130391 (0.43662)	-0.360265 (0.44922)	-0.279085 (0.43810)
4	0.020629 (0.26024)	-0.147902 (0.26983)	0.279050 (0.26023)	-0.236941 (0.25040)
5	-0.078726 (0.19927)	-0.012495 (0.18666)	0.089455 (0.19965)	-0.046628 (0.15502)
6	-0.031073 (0.10629)	0.001232 (0.08808)	-0.030404 (0.12229)	-0.010116 (0.08768)
7	-5.99E-05 (0.04245)	-0.003397 (0.06865)	0.000837 (0.05714)	0.008263 (0.05304)
8	0.000607 (0.02654)	-0.001367 (0.03740)	0.005307 (0.03292)	0.003727 (0.03073)
9	0.004079 (0.01396)	-0.000448 (0.02999)	0.000435 (0.01693)	0.001124 (0.01690)
10	0.001805 (0.00579)	0.000393 (0.01818)	-0.001350 (0.00828)	0.001785 (0.00659)

#### • D'après le tableau :

Un choc sur la variable de croissance produit son effet sur la variable croissance dès la première période, tandis que les autres variables ne réagissent qu'à partir de la deuxième période. De plus, l'effet de ce choc s'atténue rapidement et converge vers 0 à partir de la troisième période.




#### • D'après les graphiques :

- La réponse de la croissance due à un choc de d(depense) est comme suit :  
Pas de réponse durant la période 1 et 2 puis une diminution pendant le période 3 puis la courbe converge vers 0.
- La réponse de la croissance due à un choc de d(inflation) est comme suit :  
Une forte réponse négative durant la période 1 et 2 puis la courbe converge vers 0.
- La réponse de la croissance due à un choc de d(masse) est comme suit :  
Une forte réponse positive durant la période 1 et 2 puis la courbe converge vers 0.

Response of DDEPENDSE:				
Period	CROISSA...	DDEPENDSE	DINFLATION	DMASSE
1	-1.840767 (0.24966)	1.139181 (0.11627)	0.000000 (0.00000)	0.000000 (0.00000)
2	-0.047551 (0.35156)	-0.280295 (0.33259)	0.362195 (0.35005)	-0.528842 (0.33808)
3	0.122725 (0.35455)	0.609676 (0.33418)	0.072754 (0.33945)	0.323515 (0.33094)
4	-0.025818 (0.19075)	0.003004 (0.25083)	-0.188896 (0.19471)	0.149124 (0.19406)
5	0.060742 (0.15585)	0.225393 (0.21318)	-0.085071 (0.14163)	0.085947 (0.13995)
6	0.024173 (0.07367)	-0.057006 (0.13711)	0.014617 (0.08299)	0.007558 (0.07649)
7	0.003895 (0.04732)	0.099247 (0.12574)	-0.022800 (0.04751)	0.021079 (0.05540)
8	0.000405 (0.02747)	-0.034617 (0.08055)	-0.003061 (0.03025)	-0.006468 (0.03096)
9	-0.001681 (0.01797)	0.042849 (0.07274)	-0.007053 (0.01675)	0.008676 (0.02396)
10	-0.001299 (0.00950)	-0.019682 (0.04741)	0.002214 (0.01168)	-0.004433 (0.01058)

- D'après le tableau :

Un choc sur la variable de d(depense) produit son effet sur les variables croissance et d(depense) dès la première période, tandis que les autres variables ne réagissent qu'à partir de la deuxième période. De plus, l'effet de ce choc s'atténue rapidement et converge vers 0 à partir de la 4ème période.



- D'après les graphiques :

- La réponse de d(depense) due à un choc de d(inflation) est comme suit :

Une forte réponse négative durant la période 1, 2 et 3 puis la courbe converge vers 0.


- La réponse de d(depense) due à un choc de d(masse) est comme suit :

Une forte réponse négative durant la période 1 et 2 puis la courbe converge vers 0.

Response of DINFLATION:				
Period	CROISSA...	DDEPENDSE	DINFLATION	DMASSE
1	-0.242126 (0.40278)	-0.076486 (0.40194)	2.784210 (0.28416)	0.000000 (0.00000)
2	0.387766 (0.45157)	0.762321 (0.41959)	-0.134987 (0.43971)	0.191324 (0.43147)
3	0.290347 (0.45411)	0.316650 (0.43403)	-0.557302 (0.44366)	0.516343 (0.42795)
4	-0.009724 (0.27696)	0.238850 (0.24138)	-0.239322 (0.27394)	0.196571 (0.24456)
5	0.037826 (0.22400)	-0.034452 (0.19894)	0.045927 (0.21986)	-0.054924 (0.17064)
6	0.015494 (0.09065)	0.079025 (0.14132)	0.021361 (0.11392)	0.001187 (0.10780)
7	-0.013574 (0.06374)	2.18E-05 (0.08924)	-0.022067 (0.07133)	0.002237 (0.05795)
8	-0.005413 (0.02617)	0.032990 (0.06371)	-0.012983 (0.03567)	0.006361 (0.03649)
9	-0.001396 (0.00887)	-0.008307 (0.04141)	0.004238 (0.02121)	-0.002052 (0.01586)
10	0.000234 (0.00518)	0.014766 (0.03373)	-0.001156 (0.01040)	0.003302 (0.00925)

- D'après le tableau :

Un choc sur la variable de d(inflation) produit son effet sur toutes les variables sauf la variable d(masse) dès la première période, tandis que cette dernière ne réagit qu'à partir de la deuxième période. De plus, l'effet de ce choc s'atténue rapidement aussi et converge vers 0 à partir de la 4ème période.



• **D'après les graphiques :**


- La réponse de d(inflation) due à un choc de d(depense) est comme suit :  
Une forte réponse positive durant la période 1 et 2 puis la courbe converge vers 0.
- La réponse de d(inflation) due à un choc de d(masse) est comme suit :  
Une réponse positive qui persiste durant les périodes 1, 2, 3 et 4 puis elle converge vers 0.

Response of DINFATION:				
Period	CROISSA...	DDEPENDSE	DINFATION	DMASSE
1	-1.193525 (1.23689)	2.110821 (1.21187)	-0.556403 (1.19122)	8.243612 (0.84136)
2	1.799107 (1.38608)	0.256580 (1.30185)	-1.004646 (1.38088)	1.849558 (1.34089)
3	2.475738 (1.41404)	0.174555 (1.30032)	0.209069 (1.32715)	1.131914 (1.29985)
4	0.446052 (0.77944)	0.267068 (0.96072)	-0.607845 (0.72142)	0.614208 (0.84943)
5	0.047571 (0.62279)	-0.074973 (0.83696)	-0.330785 (0.53016)	-0.120827 (0.64960)
6	-0.034152 (0.31880)	-0.105544 (0.44348)	0.117020 (0.25700)	-0.170791 (0.38963)
7	-0.085952 (0.21845)	-0.046605 (0.31558)	0.075956 (0.17583)	-0.101019 (0.18862)
8	-0.037026 (0.11185)	-0.013879 (0.13901)	0.013946 (0.10288)	-0.035409 (0.10461)
9	-0.012610 (0.05326)	-0.005585 (0.10692)	0.005516 (0.05565)	-0.000225 (0.07477)
10	-0.001813 (0.03148)	-0.001212 (0.05371)	0.002334 (0.02463)	0.003248 (0.04366)

Cholesky One S.D. (d.f. adjusted)  
Cholesky ordering: CROISSANCE DDEPENDSE DINFATION  
DMASSE  
Standard errors: Analytic

• **D'après le tableau :**

Un choc sur la variable de d(masse) produit son effet sur toutes les variables dès la première période. De plus, l'effet de ce choc s'atténue rapidement aussi et converge vers 0 à partir de la 5eme période.



• **D'après les graphiques :**

- La réponse de d(masse) due à un choc de d(depense) est comme suit :  
Une réponse positive durant la 1ere période puis la courbe converge vers 0.
- La réponse de d(masse) due à un choc de d(inflation) est comme suit :  
Une faible réponse négative qui persiste durant les périodes 1, 2, 3 et 4 puis elle converge vers 0.

b) Décomposition de la variance :

L'objectif de la décomposition de la variance est de calculer la contribution de chacune des innovations à la variance de l'erreur. De façon heuristique, on écrit l'erreur de prévision à un horizon  $h$  (ici  $h$  va de 1 à 10) en fonction de la variance de l'erreur attribué à chacune des 2 variables.

Les résultats relatifs à l'étude de la décomposition de la variance se présentent comme suit :

Variance Decomposition of CROISSANCE:						Variance Decomposition of DINFLATION:					
Period	S.E.	CROISSA...	DDEPENDSE	DINFLATION	DMASSSE	Period	S.E.	CROISSA...	DDEPENDSE	DINFLATION	DMASSSE
1	2.796432	100.0000	0.000000	0.000000	0.000000	1	2.783171	2.114312	0.437603	97.44808	0.000000
2	2.993355	87.33869	0.021879	8.323225	4.316204	2	3.045081	6.727180	10.17849	81.60795	1.486376
3	3.010302	86.46563	0.960793	8.283012	4.290563	3	3.070298	6.837287	10.04200	80.56285	2.557866
4	3.010629	86.45522	0.965433	8.282014	4.297337	4	3.074076	6.822318	10.04360	80.45053	2.683556
5	3.010705	86.45142	0.965534	8.282813	4.300234	5	3.074424	6.821310	10.04982	80.44015	2.688718
6	3.010715	86.45084	0.965646	8.282978	4.300535	6	3.074443	6.821440	10.05051	80.43936	2.688691
7	3.010716	86.45080	0.965667	8.282993	4.300544	7	3.074445	6.821458	10.05052	80.43930	2.688721
8	3.010716	86.45079	0.965669	8.282993	4.300544	8	3.074445	6.821458	10.05052	80.43929	2.688729
9	3.010716	86.45079	0.965669	8.282993	4.300544	9	3.074445	6.821458	10.05052	80.43929	2.688729
10	3.010716	86.45079	0.965669	8.282993	4.300544	10	3.074445	6.821458	10.05052	80.43929	2.688729

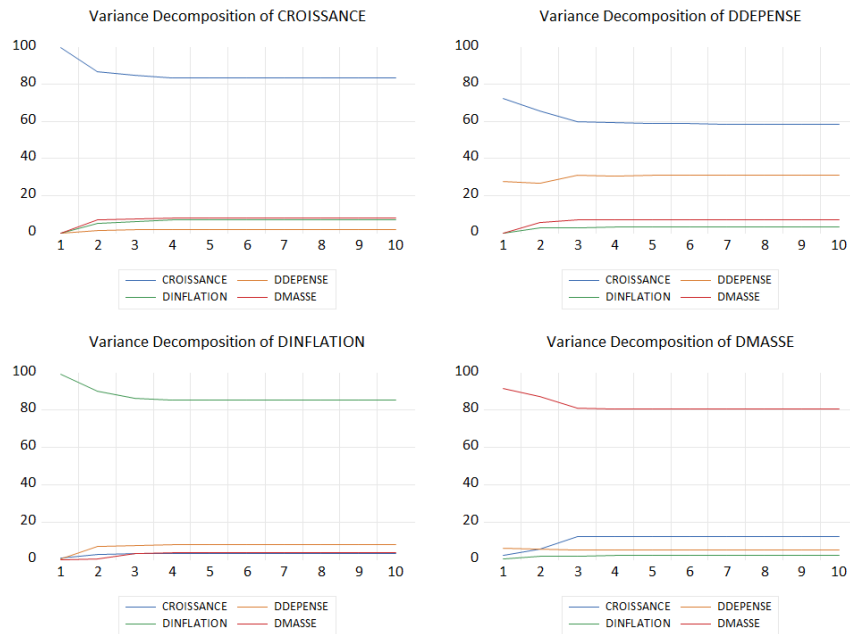
Variance Decomposition of DDEPENDSE:						Variance Decomposition of DMASSSE:					
Period	S.E.	CROISSA...	DDEPENDSE	DINFLATION	DMASSSE	Period	S.E.	CROISSA...	DDEPENDSE	DINFLATION	DMASSSE
1	2.216509	69.51692	30.48308	0.000000	0.000000	1	8.441827	2.438122	3.071378	0.787532	93.70297
2	2.360791	61.62282	26.90903	8.905956	2.562194	2	8.880122	4.344912	2.799376	1.414674	91.44104
3	2.375352	61.04300	27.61808	8.799237	2.539690	3	8.965609	4.292391	2.791762	2.155894	90.75995
4	2.375759	61.03000	27.60874	8.797276	2.563989	4	8.974132	4.287948	2.864975	2.209036	90.63804
5	2.375847	61.02572	27.60672	8.799295	2.568263	5	8.974569	4.289045	2.870526	2.211054	90.62937
6	2.375857	61.02522	27.60676	8.799493	2.568527	6	8.974598	4.289202	2.870760	2.211043	90.62899
7	2.375858	61.02519	27.60678	8.799503	2.568529	7	8.974602	4.289206	2.870757	2.211064	90.62897
8	2.375858	61.02519	27.60678	8.799502	2.568529	8	8.974603	4.289205	2.870759	2.211068	90.62897
9	2.375858	61.02519	27.60678	8.799502	2.568529	9	8.974603	4.289205	2.870759	2.211068	90.62897
10	2.375858	61.02519	27.60678	8.799502	2.568529	10	8.974603	4.289205	2.870759	2.211068	90.62897

Cholesky One S.D. (d.f. adjusted)  
Cholesky ordering: CROISSANCE DDEPENDSE DINFLATION DMASSSE

Le tableau ci-dessus de la décomposition de la variance indique que :

- La variance de l'erreur de prévision de la série représentant la croissance est dû à 86,45% à ses propres innovations-chocs
- La variance de l'erreur de prévision de la série représentant la d(depense) est dû à 27,6% à ses propres innovations-chocs
- La variance de l'erreur de prévision de la série représentant la d(inflation) est dû à 80,43% à ses propres innovations-chocs
- La variance de l'erreur de prévision de la série représentant la d(masse) est dû à 90,62% à ses propres innovations-chocs

### Variance Decomposition using Cholesky (d.f. adjusted) Factors



## 5) VECM :

### Vector Error Correction Estimates

Date: 05/09/24 Time: 10:26

Sample (adjusted): 1975 2022

Included observations: 48 after adjustments

Standard errors in ( ) & t-statistics in [ ]

Cointegrating Eq:	CointEq1			
CROISSANCE(-1)	1.000000			
DDEPENSE(-1)	0.642366 (0.31335) [ 2.04998]			
DINFLATION(-1)	-1.279800 (0.24870) [-5.14600]			
DMASSE(-1)	0.016158 (0.06757) [ 0.23914]			
C	-2.379390			
Error Correction:	D(CROISSA...	D(DDEPEN...	D(DINFLATI...	D(DMASSE)
CointEq1	-0.221303 (0.17665) [-1.25280]	0.196002 (0.12997) [ 1.50807]	0.817163 (0.14225) [ 5.74456]	0.535495 (0.51646) [ 1.03686]
D(CROISSANCE(-1))	-0.165028 (0.28406) [-0.58096]	-0.397716 (0.20900) [-1.90295]	-0.218940 (0.22875) [-0.95712]	-0.621302 (0.83050) [-0.74811]

D(DDEPENSE(-1))	0.176429 (0.32764) [ 0.53849]	-0.863842 (0.24106) [-3.58352]	-0.018928 (0.26384) [-0.07174]	-0.514392 (0.95790) [-0.53700]
-----------------	-------------------------------------	--------------------------------------	--------------------------------------	--------------------------------------

D(DINFLATION(-1))	-0.287071 (0.15726) [-1.82546]	0.222443 (0.11570) [ 1.92252]	0.062702 (0.12664) [ 0.49513]	-0.008742 (0.45977) [-0.01901]
-------------------	--------------------------------------	-------------------------------------	-------------------------------------	--------------------------------------

D(DMASSE(-1))	0.098153 (0.05236) [ 1.87460]	-0.073584 (0.03852) [-1.91010]	-0.013384 (0.04216) [-0.31742]	-0.426732 (0.15308) [-2.78762]
---------------	-------------------------------------	--------------------------------------	--------------------------------------	--------------------------------------

C	0.162779 (0.49570) [ 0.32838]	-0.107114 (0.36471) [-0.29369]	-0.021414 (0.39918) [-0.05365]	-0.068002 (1.44926) [-0.04692]
---	-------------------------------------	--------------------------------------	--------------------------------------	--------------------------------------

R-squared	0.324273	0.462968	0.571728	0.191903
Adj. R-squared	0.243829	0.399036	0.520743	0.095701
Sum sq. resids	495.0004	267.9603	320.9931	4231.152
S.E. equation	3.433034	2.525867	2.764542	10.03702
F-statistic	4.031050	7.241525	11.21370	1.994796
Log likelihood	-124.1096	-109.3804	-113.7143	-175.6057
Akaike AIC	5.421235	4.807515	4.988096	7.566906
Schwarz SC	5.655135	5.041415	5.221996	7.800806
Mean dependent	0.142312	-0.064811	-0.030090	-0.040819
S.D. dependent	3.947918	3.258263	3.993365	10.55477

Determinant resid covariance (dof adj.)	12011.56
Determinant resid covariance	7040.955
Log likelihood	-485.0642
Akaike information criterion	21.37767
Schwarz criterion	22.46921
Number of coefficients	28

## VAR Model - Substitute Coefficients :

=====

$$\begin{aligned}\Delta croissances_t = & -0.221[ croissances_{t-1} + 0.642\Delta depense_{t-1} - 1.279\Delta inflation_{t-1} \\ & + 0.016 \Delta masse_{t-1} - 2.379] - 0.165\Delta croissances_t + 0.176\Delta^2 depense_{t-1} \\ & - 0.287\Delta^2 inflation_{t-1} + 0.098\Delta^2 masse_{t-1} + 0.162\end{aligned}$$

$$\begin{aligned}\Delta^2 depense_t = & 0.196[ croissances_{t-1} + 0.642\Delta^2 depense_{t-1} - 1.279\Delta inflation_{t-1} \\ & + 0.016 \Delta masse_{t-1} - 2.379] - 0.397\Delta croissances_t - 0.863\Delta^2 depense_{t-1} \\ & + 0.222\Delta^2 inflation_{t-1} - 0.073\Delta^2 masse_{t-1} - 0.107\end{aligned}$$

$$\begin{aligned}\Delta^2 inflation_t = & 0.817[ croissances_{t-1} + 0.642\Delta^2 depense_{t-1} - 1.279\Delta inflation_{t-1} \\ & + 0.016 \Delta masse_{t-1} - 2.379] - 0.218\Delta croissances_t - 0.018\Delta^2 depense_{t-1} \\ & + 0.062\Delta^2 inflation_{t-1} - 0.013\Delta^2 masse_{t-1} - 0.021\end{aligned}$$

$$\begin{aligned}\Delta^2 masse_t = & 0.535[ croissances_{t-1} + 0.642\Delta^2 depense_{t-1} - 1.279\Delta inflation_{t-1} + \\ & 0.016 \Delta masse_{t-1} - 2.379] - 0.621\Delta croissances_t - 0.514\Delta^2 depense_{t-1} - \\ & 0.0087\Delta^2 inflation_{t-1} - 0.426\Delta^2 masse_{t-1} - 0.068\end{aligned}$$

# CONCLUSION

---

Notre étude de VAR a permis de mettre en évidence la complexité de la relation entre la masse monétaire, dépense et l'inflation, qui peut être influencée par de nombreux autres facteurs économiques et politiques. Bien qu'une corrélation positive entre ces deux variables ait été observée à court terme, la nature de cette relation peut être moins évidente à plus long terme. De fait, l'interaction de facteurs tels que les fluctuations économiques, les politiques fiscales et monétaires, la productivité et les fluctuations des taux de change peut jouer un rôle important dans la relation entre la masse monétaire et l'inflation.

Ainsi, il est crucial de prendre en compte ces facteurs supplémentaires lors de l'analyse de la relation entre la masse monétaire et l'inflation à la Royaume-Uni. En effet, ces éléments peuvent avoir une influence significative sur l'évolution de la relation entre les deux variables au fil du temps. En somme, notre étude souligne l'importance d'une approche globale et contextuelle dans l'analyse de la relation entre la masse monétaire et l'inflation à la Royaume-Uni, en vue d'obtenir une vision complète et précise de cette dynamique complexe.

# Bibliographie

---

- Alloza, M., (2017), A Very Short Note on Computing Impulse Response Functions
- Banque Mondiale
- Économétrie : Régis Bourbonnais
- <https://www.macrotrends.net/>
- Investments, economic growth and employment: var method for Romania, sciendo
- James D. Hamilton: Time Series Analysis, Princeton University Press (1994). Chapter 11, Pages 318-320
- Sorensen, B. E., (2005), Granger causality, Economics, 7395, accessible en ligne sur [https://ssl.uh.edu/~bsorensen/gra\\_caus.pdf](https://ssl.uh.edu/~bsorensen/gra_caus.pdf).



# ANNEX

---

## I. Série temporelle :

### a) Définition :

Une série temporelle (chronique) est une séquence d'observations d'une même variable au cours du temps, repérées à des intervalles de temps réguliers. Chaque observation correspond à une réalisation particulière d'une variable aléatoire  $Y_{t(t=1,2,...,n)}$ , où le nombre  $n$  est appelé la longueur de la série. L'indice temporel peut être, selon les cas, l'heure, le jour, le mois, l'année, etc.

### b) Description d'une série chronologique :

Une série chronologique  $X_t$  est le résultat de différentes composantes fondamentales :

- *La tendance* (ou trend en anglais)  $Z_t$  représente l'évolution d'une série temporelle au cours du temps.

- *La composante saisonnière* (ou saisonnalité)  $S_t$  correspond à un phénomène qui se répète à intervalles de temps réguliers. En général, c'est un phénomène saisonnier d'où le terme de variations saisonnières.

- *La composante résiduelle* (ou bruit)  $\varepsilon_t$  correspond à des fluctuations irrégulières, en général de faible intensité mais de nature aléatoire

## II. Stationnarité

Un prérequis pour de nombreux modèles de séries temporelles, y compris le modèle VAR, est que les données soient stationnaires.

### a) Définition :

Une série chronologique est stationnaire si elle est la réalisation d'un processus stationnaire. Ceci implique que la série ne comporte ni tendance, ni saisonnalité et, plus généralement, aucun facteur n'évoluant avec le temps. La stationnarité en sens large peut être définie par les conditions suivantes :

$$E(X_t) = \mu$$

$$\text{Var}(X_t) = \sigma^2,$$

$$\text{Cov}(X_t, X_{t+k}) = \gamma(k)$$

La stationnarité stricte exige en plus que la distribution jointe des observations soit invariante par translation dans le temps.

### b) Test de racine unitaire :

Il existe plusieurs tests pour vérifier la stationnarité d'une série temporelle :

#### i. Test de Dickey-Fuller augmenté (ADF)

Le test de Dickey-Fuller augmenté (ADF) est un test statistique couramment utilisé pour déterminer si une série temporelle est stationnaire. L'hypothèse nulle de ce test est que la série a

une unité racine, c'est-à-dire qu'elle est non stationnaire. Si la p-value obtenue par le test est inférieure à un certain seuil (généralement 0.05), alors on peut rejeter l'hypothèse nulle et conclure que la série est stationnaire.

ii. Test PP (Phillips-Perron) :

Le test de Phillips-Perron (PP) est un test de racine unitaire pour tester la non-stationnarité dans une série chronologique. Il s'agit d'une extension du test de Dickey-Fuller (ADF) qui permet de tenir compte de la possibilité que la série chronologique comporte une tendance déterministe.

Le test PP utilise une régression linéaire pour modéliser la série chronologique en fonction de sa valeur retardée et de la tendance linéaire estimée. Le test compare ensuite les résidus de cette régression à une distribution normale pour déterminer s'ils sont stationnaires ou non.

iii. Test KPSS (Kwiatkowski-Phillips-Schmidt-Shin) :

Le test KPSS est un autre test statistique utilisé pour vérifier la stationnarité d'une série temporelle. Contrairement à l'ADF, l'hypothèse nulle pour le test KPSS est que la série est stationnaire. Si la p-value obtenue par le test est supérieure à un certain seuil, alors on ne peut pas rejeter l'hypothèse nulle et on peut conclure que la série est stationnaire.

Le test KPSS utilise une régression linéaire pour modéliser la série chronologique en fonction de sa valeur retardée. Le test compare ensuite la somme des carrés des résidus de cette régression à une distribution de référence pour déterminer s'ils sont stationnaires ou non.

iv. Autre test :

Il existe également d'autres tests de stationnarité, comme le test DF-GLS...

En outre, la visualisation des données (par exemple, à l'aide de graphiques de séries temporelles, de graphiques d'autocorrélation, etc.) peut également aider à déterminer si une série est stationnaire ou non.

.

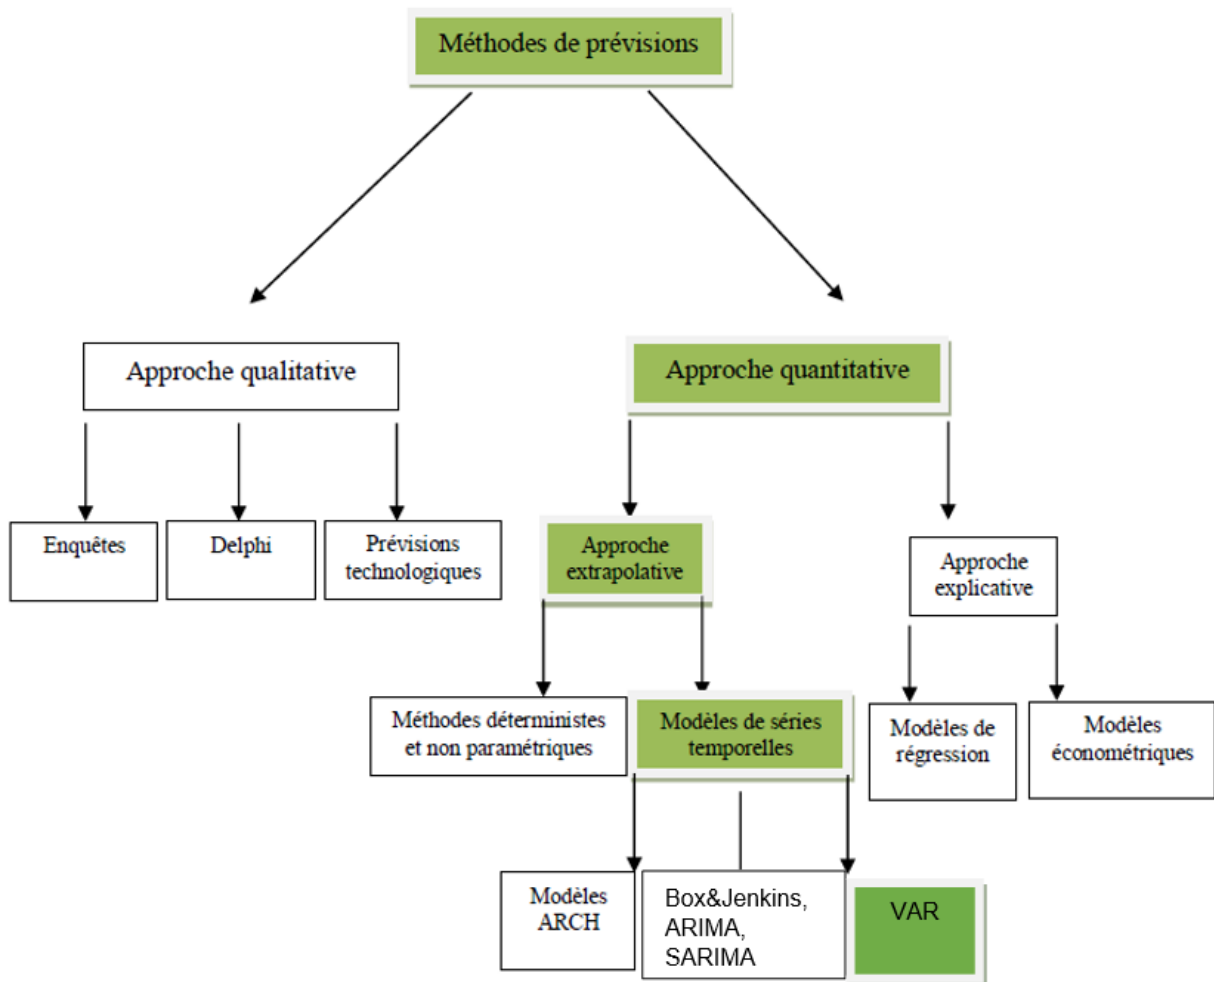
### III. Modélisation :

#### Définition :

L'un des objectifs les plus importants de l'étude d'une série chronologique est la prévision des valeurs futures de cette série. Pour cela, on utilise généralement des modèles de prévision. Les modèles de prévision peuvent être de différents types, tels que les modèles de régression, les modèles ARIMA (Autoregressive Integrated Moving Average), les modèles de lissage exponentiel, le modèle VAR (Vector Autoregression) etc...

Une fois que le modèle de prévision approprié est sélectionné, il peut être utilisé pour prévoir les valeurs futures de la série chronologique. Cela peut être très utile dans de nombreux domaines où la prévision des valeurs futures est importante pour la prise de décision et la planification. Cependant, il est important de noter que les modèles de prévision ne sont pas toujours précis à 100 % et que les prévisions peuvent varier en fonction des changements dans les données ou les variables d'entrée.

Pour résumer les différentes approches des techniques de prévision, nous fournissons le schéma ci-dessous :



Dans notre cas, notre projet se focalisera sur une approche extrapolative qui utilise une modélisation VAR.

## Choix du $p$ optimal

Pour un modèle VAR, le choix de l'ordre ( $p$ ) est une étape cruciale. L'ordre du modèle VAR est le nombre de retards des séries temporelles à inclure dans le modèle. Plusieurs critères peuvent être utilisés pour déterminer l'ordre optimal, y compris le critère d'information d'Akaike (AIC), le critère d'information bayésien (BIC), le critère d'erreur de prédiction finale (FPE), et le critère d'information d'Hannan-Quinn (HQIC).

### ❖ Akaike Information Criterion (AIC)

L'AIC est une mesure de la qualité d'un modèle statistique. Pour un modèle donné, l'AIC prend en compte à la fois la complexité du modèle (nombre de paramètres) et la capacité du modèle à expliquer les données (la vraisemblance). Un modèle avec un AIC plus petit est généralement préféré.

### ❖ Bayesian Information Criterion (BIC)

Le BIC est similaire à l'AIC, mais il pénalise plus fortement les modèles avec plus de paramètres. Cela signifie que le BIC favorise des modèles plus simples que l'AIC.

### ❖ Final Prediction Error (FPE)

Le FPE est une autre mesure de la qualité du modèle qui prend en compte le nombre de paramètres du modèle. Comme l'AIC et le BIC, un modèle avec un FPE plus petit est généralement préféré.

### ❖ Hannan-Quinn Information Criterion (HQIC)

Le HQIC est une autre mesure qui pénalise la complexité du modèle. Il est similaire à l'AIC et au BIC, mais il pénalise moins fortement les modèles avec plus de paramètres que le BIC.

Dans la pratique, l'AIC, le BIC, le FPE et le HQIC peuvent donner des ordres optimaux différents. En général, il est conseillé de choisir le modèle avec le plus petit critère d'information, bien qu'il puisse être utile de vérifier la performance de prédiction du modèle pour différents ordres.

## IV. Prédiction avec Python :